AbosCluster

Manuel d'utilisation

Version 1.0

Classification des trajectoires pondérales
après chirurgie bariatrique

Données longitudinales éparses, modèles à classes latentes et k-means fonctionnel

Auteurs : Komlan NOUKPOAPE & Cristian PREDA

Inria – Promoteur : CHU de Lille (University Hospital, Lille)

3 novembre 2026

Guide du lecteur : les données analysées

Tous les chiffres et toutes les figures de ce manuel viennent d'un seul jeu de données, tiré de la cohorte ABOS (*A Biological Atlas of Severe Obesity*, CHU de Lille). L'**annexe A** le décrit en détail.

— **Échantillon source** : 1 443 patients opérés d'une chirurgie bariatrique et 8 734 mesures, soit de 2 à 7 visites par patient (6 en moyenne), réparties sur 95 mois de suivi au plus. Les visites sont irrégulières et propres à chaque patient (données longitudinales éparses).

— **Échantillon analysé** : le statut tabagique manque pour 5 patients (0.3 %), sur l'ensemble de leurs 26 mesures. Ces lignes sont **supprimées avant toute analyse** : **1 438 patients et 8 708 mesures**. Les graphiques descriptifs (section 3.5) et tous les résultats de clustering (sections 5.10, 6.4 et 8.3) portent sur cet échantillon. Aucune valeur atypique de Poids ou de TWL n'a été supprimée (annexe, section A.2).

— **Réponses pondérales étudiées** : le Poids (kg), l'indice de masse corporelle (BMI) et le pourcentage de perte de poids totale (TWL). Toutes trois sont des transformations du poids corporel (annexe, section A.3).

— **Covariables** : l'âge à l'intervention, la technique chirurgicale, le statut tabagique et le statut diabétique. Une analyse *avec covariables* les inclut toutes les quatre ; une analyse *sans covariable*, aucune.

Où retrouver les exemples. Les graphiques descriptifs sont en section 3.5, l'analyse InfoMergeCluster en section 5.10 (figure 11), l'analyse FKMS en section 6.4 (figure 12), la comparaison des données brutes et régressées à la figure 13, et la comparaison des partitions par les indices ARI (indice de Rand ajusté) et de Jaccard en section 8.3.

Doté d'une interface conviviale, le logiciel AbosCluster permet d'effectuer, sans écrire de code, des analyses exploratoires (section 3.5) et le clustering (section 4) de données longitudinales éparses, observées à des instants irréguliers. L'image ci-dessous en donne une illustration. Des boîtes de dialogue prédéfinies permettent de créer plusieurs modèles de clustering (avec ou sans covariables) et de les comparer à l'aide d'indices de concordance.

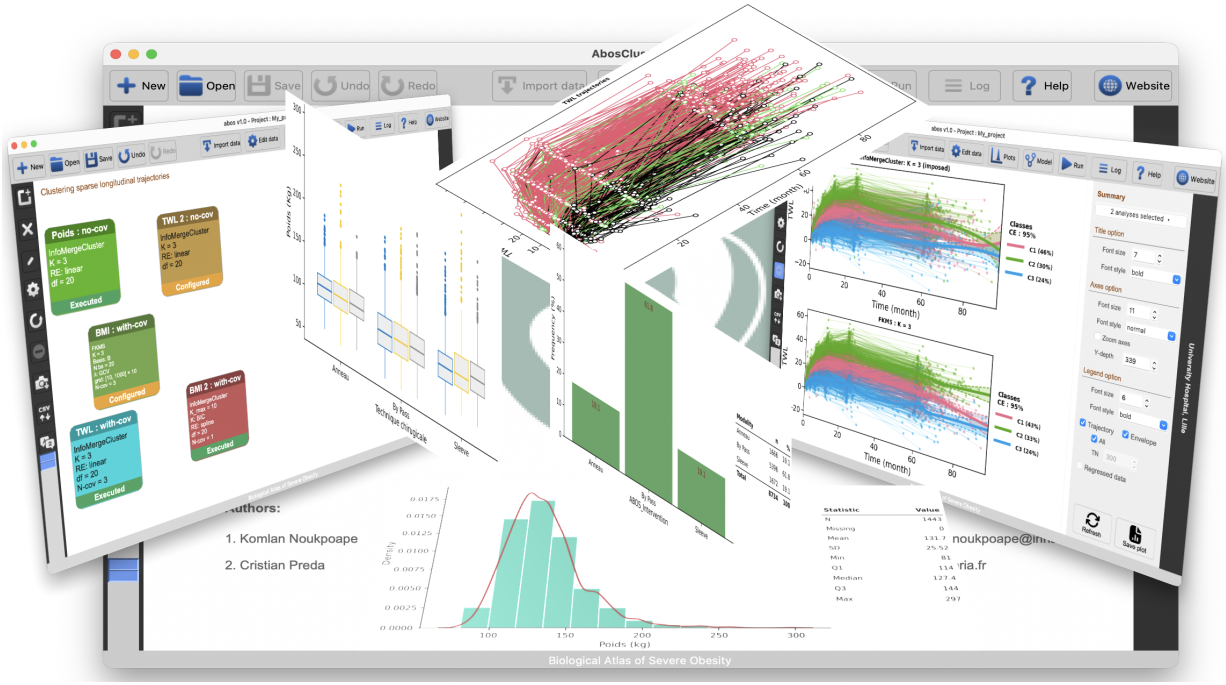


Table des matières

Avant-propos **5**

1 AbosCluster, un logiciel exécutable **6**

1.1 Ce que signifie « exécutable » . . . 6
1.2 Lancement . . . 6
1.3 Architecture de la fenêtre . . . 7
1.4 La notion de projet . . . 7
1.5 Langue, police et clavier . . . 7
1.6 Structure des données . . . 8

2 Fonctions des boutons **8**

2.1 Barre supérieure . . . 9
2.2 Barre latérale gauche . . . 10
2.3 Barre latérale droite . . . 11
2.4 Disponibilité des commandes . . . 11
2.5 Encadré d'exécution et verrouillage de l'interface . . . 11

3 Préparer et décrire les données **12**

3.1 Importer les données . . . 12
3.2 Préparer les données (Edit data) . . . 12
3.3 Fiche descriptive (Overview stat) . . . 13
3.4 Exporter les données et les tableaux . . . 14
3.5 Graphiques descriptifs (Plots) . . . 14
3.5.1 Exemples commentés . . . 14
3.6 Options communes à tous les graphiques . . . 20

4 Clustering des trajectoires **20**

4.1 La question clinique et ses difficultés . . . 20
4.2 Vue d'ensemble . . . 21
4.3 Étape 1 : créer une boîte d'analyse . . . 21
4.4 Étape 2 : choisir la méthode et la configurer . . . 21
4.5 Étape 3 : exécuter . . . 21
4.6 Lire une boîte d'analyse . . . 22
4.7 Gérer les boîtes . . . 22

5 InfoMergeCluster : mélange de modèles linéaires mixtes **22**

5.1 Modèle . . . 22
5.2 Trajectoires moyennes : splines pénalisées . . . 23
5.3 Variabilité individuelle (re) . . . 23
5.4 Lois a priori sur la structure de variance . . . 24
5.5 Initialisation par micro-classes et fusions . . . 24
5.6 Choix du nombre de classes . . . 24
5.7 Covariables . . . 25
5.8 Affectation des patients . . . 25
5.9 Paramètres . . . 25
5.10 Clustering avec InfoMergeCluster : comment ça marche ? . . . 26

6 FKMS : k-means fonctionnel 29
6.1 Principe . . . 29
6.2 Lissage et choix de λ par validation croisée généralisée . . . 29
6.3 Covariables, enveloppes et nombre de classes . . . 30
6.4 Clustering avec FKMS : comment ça marche ? . . . 31

7 InfoMergeCluster vs FKMS 34

8 Lire, comparer et exporter les résultats 35
8.1 Le panneau des résultats . . . 35
8.2 Options propres à chaque graphique . . . 35
8.3 Comparer plusieurs analyses . . . 37
8.3.1 Boîtes de comparaison . . . 37
8.3.2 Indices de concordance . . . 38
8.3.3 Afficher et exporter les indices . . . 38
8.3.4 Exemple : trois analyses du Poids . . . 39
8.4 Exporter . . . 40

A Description des données de la cohorte ABOS 41
A.1 Données et schéma d'observation . . . 41
A.2 Valeurs manquantes . . . 42
A.3 Relations déterministes entre les variables réponses . . . 43

Références 44

Avant-propos

La réponse pondérale à la chirurgie bariatrique varie d'un patient à l'autre. Après une perte rapide, certains se stabilisent, d'autres reprennent du poids après leur perte maximale, d'autres ne perdent jamais assez. Identifier ces profils et les patients qui s'y rattachent sert le suivi post-opératoire, la recherche de facteurs pronostiques et la compréhension physiopathologique de la réponse. AbosCluster réalise cette classification sans code, à partir des mesures pondérales répétées (poids, indice de masse corporelle ou pourcentage de perte de poids totale, TWL) recueillies aux visites de suivi.

Public visé. Chirurgiens bariatriques, endocrinologues, nutritionnistes, médecins des centres spécialisés de l'obésité, attachés de recherche clinique et biostatisticiens. Le manuel suppose connus les indicateurs du suivi pondéral et la statistique descriptive ; modèle linéaire mixte, classe latente et spline sont présentés là où ils interviennent.

Organisation. Le manuel suit l'ordre dans lequel une étude est conduite.

Section	Contenu	Question à laquelle elle répond
1	Le logiciel et le projet	Comment lancer AbosCluster, organiser une étude et structurer les données ?
2	Les boutons	À quoi sert chaque commande, et quand est-elle disponible ?
3	Préparation et description	Les données sont-elles complètes, cohérentes et exploitables ?
4	Étapes d'un clustering	Comment créer, configurer et exécuter une analyse ?
5	InfoMergeCluster	Que fait la méthode probabiliste, et comment régler ses paramètres ?
6	FKMS	Que fait le k-means fonctionnel, et comment régler ses paramètres ?
7	InfoMergeCluster vs FKMS	Qu'est-ce qui distingue les deux méthodes ?
8	Résultats	Comment lire, interpréter et exporter les classes obtenues, et mesurer la concordance de deux partitions (ARI, indice de Jaccard) ?

Conventions de lecture.

— Les libellés de l'interface sont écrits en gras et restent en anglais, comme à l'écran : **Run**, **Edit data**, **Overview stat**.

— Une suite de clics s'écrit avec une flèche : **Edit data** → **Overview stat** → **Export stat**.

— La *réponse* désigne la grandeur pondérale dont on étudie l'évolution (poids, indice de masse corporelle, pourcentage de perte de poids totale ou TWL). Le *délai* est le temps écoulé depuis l'intervention. Les *covariables* sont les caractéristiques des patients prises en compte par le modèle (âge, statut diabétique, statut tabagique, technique opératoire …).

— Une *classe* (ou *cluster*) est un groupe de patients partageant une même dynamique d'évolution pondérale ; la *trajectoire moyenne* d'une classe est la courbe estimée qui résume cette dynamique.

— Encadrés bleus : sens statistique d'un résultat ou d'un réglage. Encadrés bruns : vigilance clinique et précautions d'interprétation.

Statut de l'outil

AbosCluster est un outil d'analyse exploratoire et de recherche clinique. Ses classes sont des constructions statistiques tirées d'un échantillon, ni diagnostics ni indications thérapeutiques. Toute décision concernant un patient relève du jugement médical.

1. AbosCluster, un logiciel exécutable

AbosCluster v1.0 est une application de bureau autonome développée en Python dans l'environnement *Spyder*, avec le module **tkinter** : elle se lance d'un double-clic, sans avoir à installer Python ni aucune bibliothèque. Son nom renvoie à l'*Atlas Biologique de l'Obésité Sévère* (*A Biological Atlas of Severe Obesity*), cohorte prospective promue par le CHU de Lille et enregistrée sous la référence NCT01129297. Le bouton **Website** ouvre la page de l'étude sur ClinicalTrials.gov.

1.1 Ce que signifie « exécutable »

Le programme est écrit en Python puis « gelé » : interpréteur, bibliothèques et ressources graphiques tiennent dans un seul paquet. À version, données et paramètres identiques, les résultats sont identiques si la graine aléatoire est fixée (`seed`, sections 5.9 et 6.3) ; vide, elle change à chaque exécution. Cette reproductibilité ne vaut qu'*à l'intérieur d'AbosCluster* : une même graine ne redonne pas les tirages de R (`set.seed()`), dont le générateur, les fonctions de tirage et certains algorithmes d'initialisation diffèrent (remarque de la section 5.9).

Composant embarqué	**Rôle dans AbosCluster**
Tkinter et tkmacosx	Interface graphique : fenêtres, boutons, listes, boîtes de dialogue
pandas et NumPy	Lecture, filtrage et calculs sur les tableaux de données
InfoMergeCluster	Modèle linéaire mixte à classes latentes (section 5)
FKMS	k-means fonctionnel (section 6)
Matplotlib	Ensemble des graphiques
python-docx et openpyxl	Exports Word et Excel
Dossier `AbosCluster`	Icônes des boutons et manuel d'utilisation

1.2 Lancement

1. Copier le dossier de l'application sur le disque, sans séparer l'exécutable de ses ressources.
2. Double-cliquer sur l'exécutable AbosCluster. Sous macOS, un premier lancement peut exiger une autorisation dans les réglages de sécurité.
3. La fenêtre principale s'ouvre ; sa barre de titre affiche « AbosCluster v1.0 », puis le nom du projet ouvert.

1.3 Architecture de la fenêtre

Zone	Position	Contenu
Barre supérieure	Haut	Projet, données, graphiques, analyses, exécution, résultats, aide
Barre latérale	Gauche	Gestion des boîtes d'analyse, arrêt, capture, export, langue, curseur de taille et de zoom
Panneau central	Centre	Espace de travail : tableaux, graphiques, boîtes d'analyse et de comparaison, boîtes de dialogue
Barre latérale	Droite	Gestion des boîtes de comparaison des modèles, curseur de taille de ces boîtes
Barre inférieure	Bas	Intitulé de l'étude : *Biological Atlas of Severe Obesity*

Chaque bouton de la barre supérieure affiche son propre panneau dans la zone centrale. Le curseur vertical de la barre gauche règle, selon le panneau affiché, la taille des boîtes d'analyse ou le zoom du graphique sélectionné ; celui de la barre droite règle la taille des boîtes de comparaison des modèles.

1.4 La notion de projet

Toute étude se fait dans un *projet*. Sans projet créé (**New**) ou ouvert (**Open**), les commandes d'analyse sont inaccessibles. Un projet comprend deux éléments, côte à côte :

— un fichier `<nom>.json`, lisible, qui décrit l'étude : boîtes d'analyse et de comparaison, méthodes, paramètres, indices de comparaison, filtres, conversions de variables, réglages des graphiques ;

— un dossier `<nom>_fichiers` contenant `donnees.pkl` : données importées et éditées, résultats des analyses exécutées.

Protection du travail :

— **Enregistrement automatique** : le projet est enregistré toutes les 5 minutes s'il a été modifié.

— **Historique** : les 20 dernières actions (import, édition, filtrage, création, configuration, exécution, suppression…) peuvent être annulées (**Undo**) ou rétablies (**Redo**).

— **Fermeture protégée** : si le projet contient des modifications non enregistrées, la fermeture propose **Save**, **Don't save** ou **Cancel**. La même proposition précède la création ou l'ouverture d'un autre projet.

Données de santé

Le dossier d'un projet contient des données individuelles de santé : le stocker selon les règles de l'établissement (accès restreint, sauvegarde), avec des identifiants pseudonymisés. `donnees.pkl` étant un fichier de sérialisation Python, n'ouvrir que des projets de provenance connue.

1.5 Langue, police et clavier

Le bouton de langue de la barre gauche ouvre la boîte *Langue et police / Language and font*. On y choisit la langue des instructions (*English* ou *French*), la police et sa taille ; le choix s'applique aussitôt et la langue est mémorisée. Les libellés des boutons, les noms des paramètres

et les textes des graphiques restent en anglais. Entrée valide une boîte de dialogue ; Échap la ferme.

1.6 Structure des données

AbosCluster lit des tableaux au format CSV, Excel (`.xlsx`, `.xls`) ou texte (`.txt`). Les données doivent être au *format long* : **une ligne par visite**, et non une ligne par patient. La première ligne porte les noms des colonnes.

Patient	Time	Poids	Age	Diabete	Chirurgie
P001	3.0	109.1	42.1	non	sleeve
P001	6.2	99.5	42.1	non	sleeve
P001	12.1	90.2	42.1	non	sleeve
P002	1.1	108.9	55.7	oui	RYGB
P002	11.8	88.9	55.7	oui	RYGB

Tableau 1 – Format long attendu : identifiant, délai post-opératoire (mois), réponse (poids, kg), covariables.

— **Identifiant** : un code par patient, identique sur toutes ses visites (colonne `Patient` par défaut).

— **Délai** : temps écoulé depuis l'intervention, dans une unité unique (le mois est recommandé). Les visites n'ont pas à être synchronisées entre patients, ni régulièrement espacées.

— **Réponse** : une grandeur numérique par visite.

— **Covariables** : facultatives, numériques (âge) ou qualitatives (statut diabétique, statut tabagique ...) ; une variable qualitative est codée automatiquement en indicatrices.

2. Fonctions des boutons

Les commandes se répartissent entre trois barres permanentes et les boutons propres à chaque panneau. Une commande indisponible apparaît grisée.

À l'ouverture, le panneau central présente le logiciel et ses auteurs (figure 1) ; les cinq zones sont celles de la section 1.3. Première action : créer un projet (**New**) ou en ouvrir un (**Open**).

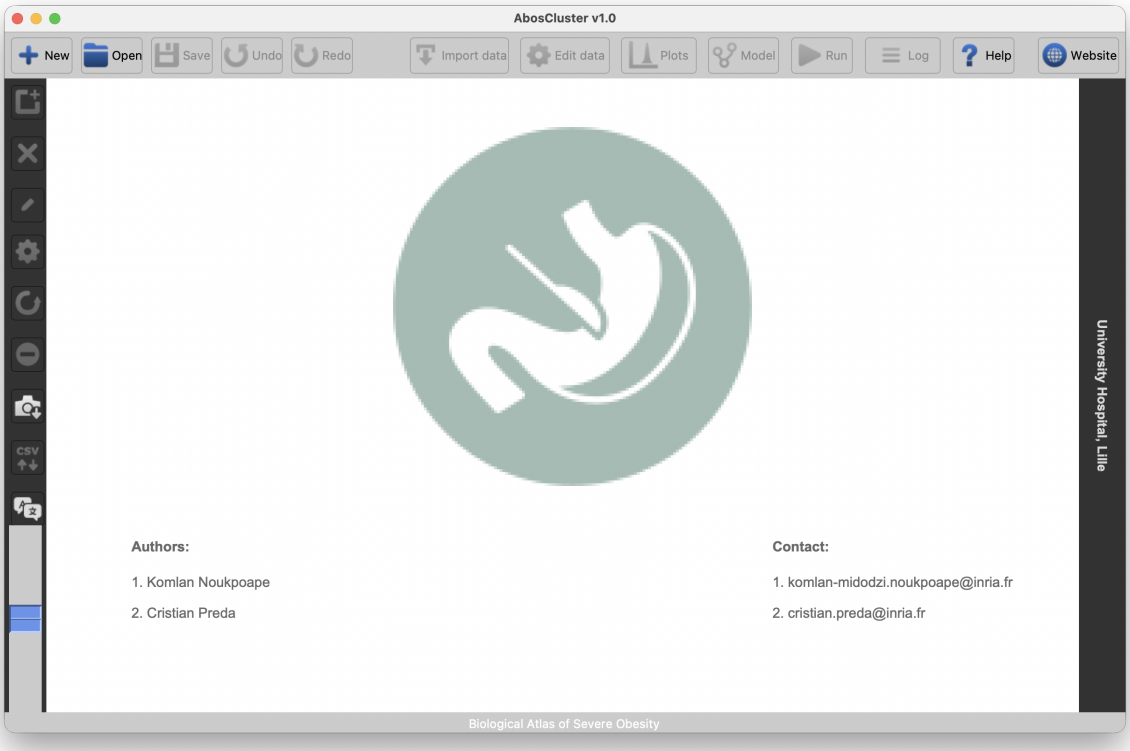


Figure 1 – Interface d'AbosCluster à l'ouverture, avant la création ou l'ouverture d'un projet. Seuls **New**, **Open**, **Help** et **Website**, ainsi que la capture de l'interface et le choix de la langue, sont actifs ; les autres commandes restent grisées.

2.1 Barre supérieure



Figure 2 – Barre supérieure d'AbosCluster, de gauche à droite.

Bouton	Fonction	Quand l'utiliser
New	Crée un projet : nom, puis emplacement du fichier JSON	Au début de toute étude
Open	Ouvre un projet et restaure données, boîtes, paramètres et résultats	Pour reprendre une étude
Save	Enregistre le projet ouvert	Après une étape importante
Undo / Redo	Annule ou rétablit une action (20 niveaux)	Après une erreur de manipulation
Import data	Importe un ou plusieurs tableaux (CSV, Excel, texte)	Juste après la création du projet
Edit data	Ouvre le panneau de préparation des données (section 3.2)	Avant toute analyse
Plots	Ouvre les graphiques descriptifs (section 3.5)	Exploration des données
Model	Affiche le panneau des boîtes d'analyse	Création et configuration (section 4)

Bouton	Fonction	Quand l'utiliser
Run	Exécute toutes les analyses configurées	Après la configuration
Log	Affiche les résultats des analyses exécutées (section 8)	Après l'exécution
Help	Ouvre le présent manuel	Pour retrouver une explication
Website	Ouvre la page de l'étude ABOS (NCT01129297)	Pour le contexte de la cohorte

2.2 Barre latérale gauche



Figure 3 – Barre latérale gauche. Les icônes claires apparaissent sur fond sombre, comme dans le logiciel.

Bouton	Fonction
Nouvelle analyse	Crée une boîte d'analyse : nom, puis couleur facultative
Supprimer	Place la boîte d'analyse sélectionnée dans la corbeille (récupérable)
Renommer	Renomme la boîte d'analyse sélectionnée ; paramètres, résultats et appartenance aux boîtes de comparaison suivent le nouveau nom
Configurer	Ouvre le choix de la méthode et ses paramètres (équivaut à un double-clic sur la boîte)
Restaurer	Ouvre la corbeille : restauration ou suppression définitive
Arrêt	Interrompt les analyses en cours ; actif (fond bleu) uniquement pendant une exécution
Capture	Enregistre une image PNG de la fenêtre telle qu'elle est affichée
Export	Exporte la liste des analyses et la classe de chaque patient (section 8.4)
Langue	Choix de la langue des instructions, de la police et de sa taille

Bouton	Fonction
Curseur vertical	Taille des boîtes d'analyse (panneau des analyses) ou zoom du graphique sélectionné

Les commandes de la barre gauche n'agissent que sur les boîtes d'analyse. Les boîtes de comparaison des modèles ont les leurs, sur la barre droite.

2.3 Barre latérale droite

La barre droite gère les *boîtes de comparaison des modèles*, qui réunissent des analyses exécutées pour mesurer la concordance de leurs partitions (section 8.3). Ses icônes sont celles de la barre gauche, dans le même ordre.

Bouton	Fonction
Nouvelle comparaison	Crée une boîte de comparaison : nom, puis couleur facultative (couleur par défaut si le choix est annulé)
Supprimer	Place la boîte de comparaison sélectionnée dans sa corbeille ; les analyses qu'elle contient ne sont pas modifiées
Renommer	Renomme la boîte de comparaison sélectionnée
Configurer	Ouvre la boîte de dialogue de la comparaison : liste des modèles, indices (ARI, Jaccard), couleur (équivaut à un double-clic sur la boîte)
Restaurer	Ouvre la corbeille des comparaisons : restauration ou suppression définitive
Curseur vertical	Taille des boîtes de comparaison, indépendante de celle des boîtes d'analyse (80 % par défaut)

2.4 Disponibilité des commandes

Pas d'import hors d'un projet, pas d'analyse sans données :

Condition	Commandes actives
Toujours	**New**, **Open**, **Help**, **Website**, capture, langue
Un projet est ouvert	**Import data**
Un projet est ouvert et des données sont importées	**Save**, **Edit data**, **Plots**, **Model**, **Run**, **Log** ; barre gauche : nouvelle analyse, suppression, renommage, configuration, corbeille, export ; barre droite : commandes des boîtes de comparaison
Une action peut être annulée ou rétablie	**Undo**, **Redo**
Une exécution est en cours	Arrêt *seulement* : toutes les autres commandes sont verrouillées (section 2.5)

2.5 Encadré d'exécution et verrouillage de l'interface

Pendant **Run**, un encadré bleu au centre du panneau indique l'analyse en cours (par exemple « Running : TWL-IM (2 / 4) »), le temps écoulé et le temps restant estimé, d'après la durée du dernier calcul de chaque analyse ou, à défaut, la durée moyenne des analyses terminées. Il se déplace à la souris et disparaît à la fin des calculs.

Pendant les calculs, l'interface est *verrouillée* : boutons, boîtes, listes, champs et curseurs ignorent clics et clavier, et le pointeur devient une montre. Seuls le bouton *Arrêt* (fond bleu) et l'encadré restent actifs. La molette fait défiler, sauf sur les listes, champs numériques et curseurs. Le verrouillage, qui empêche toute modification pendant l'estimation, est levé à la fin des calculs ou après interruption.

3. Préparer et décrire les données

Une erreur d'unité, un délai mal calculé ou un identifiant en double suffisent à créer une classe fictive. Contrôler et préparer les données vient donc avant toute modélisation.

3.1 Importer les données

Import data accepte plusieurs fichiers ; s'ils ont les mêmes colonnes (extractions par centre ou par période d'inclusion, par exemple), ils sont empilés. Pour un classeur Excel, on choisit les feuilles à importer, empilées de la même façon. Un message confirme le chargement ou donne la cause de l'échec.

3.2 Préparer les données (Edit data)

Edit data ouvre le panneau de préparation. En haut, trois blocs : à gauche, les cases **Missing value imputation**, **Convert variable** et **Filtering data**, qui ouvrent chacune leur boîte de dialogue ; au centre, recherche-remplacement de modalité et renommage de colonne ; à droite, colonnes et lignes à afficher. Quatre boutons (figure 4) : **View & Edit** applique les réglages et affiche le tableau, **Overview stat** produit la fiche descriptive (section 3.3), **Export stat** l'exporte, **Export clean** exporte les données préparées (section 3.4).

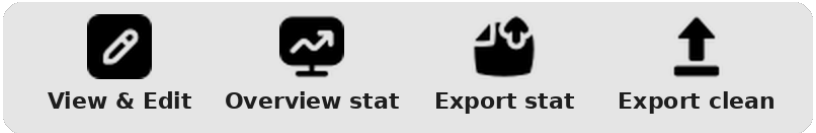


Figure 4 – Boutons du panneau **Edit data**.

Opération	Réglages	Effet
Afficher / Rafraîchir (**View & Edit**)	Colonnes et nombre de lignes à afficher (**Parameters for overview**)	Applique les réglages enregistrés et affiche le tableau ; nombre de patients, de lignes et de colonnes
Imputer (**Missing value imputation**)	Boîte de dialogue : **Column**, puis méthode **Quantitative** et méthode **Qualitative**	Traite les valeurs manquantes de la colonne choisie, ou de toutes les colonnes (détail ci-dessous)
Transformer (**Convert variable**)	**Categorizing variables**, **Convert to double**	Traite une variable codée en nombres comme qualitative (ex. 0/1), ou convertit un texte numérique en nombre réel
Filtrer (**Filtering data**)	Minimum et maximum (quantitatives) ; modalités à conserver (qualitatives)	Restreint l'analyse à une sous-population ou à une fenêtre de suivi
Rechercher et remplacer (**Search & change modality**)	Colonne, valeur cherchée, valeur de remplacement	Harmonise un codage hétérogène (ex. « Sleeve », « sleeve »)
Renommer (**Rename column**)	Ancien et nouveau nom	Clarifie un nom de colonne

Valeurs manquantes. La case **Missing value imputation** ouvre une boîte de trois lignes.

— **Column** : la colonne à traiter, ou **All columns**. Chaque colonne affiche son type et son nombre de valeurs manquantes, recalculé à chaque ouverture, par exemple `M000..TabacFumeur (character, 26 NA)`.

— **Quantitative** : `mean` ou `median` remplace la valeur manquante par la moyenne ou la médiane ; `delete` supprime la ligne.

— **Qualitative** : `modality reference` remplace la valeur manquante par le mode ; `delete` supprime la ligne.

Avec **All columns**, chaque méthode s'applique à toutes les colonnes de son type. Les choix enregistrés (**Save**) s'appliquent au prochain **View & Edit** ; décocher la case les annule. Est quantitative toute colonne numérique non déclarée qualitative par **Categorizing variables**.

Imputation et données longitudinales

Les méthodes d'AbosCluster acceptent des suivis incomplets et irréguliers : un patient vu à 3, 12 et 36 mois contribue tel quel. Ne *pas* imputer la réponse aux visites manquantes : une moyenne ou une médiane inventée écrase la variabilité individuelle et peut créer une classe « stable » artificielle. L'imputation se limite aux covariables ; si les lignes incomplètes sont rares, les supprimer est plus sûr. Parmi les données de la cohorte ABOS analysées, seul le statut tabagique est manquant, pour cinq patients (annexe, section A.2) : il est préférable de traiter cette colonne avec l'option `delete` plutôt que d'attribuer à ces patients un statut non observé.

3.3 Fiche descriptive (Overview stat)

Edit data → **Overview stat** produit une fiche de chaque colonne, calculée sur les données filtrées.

Colonne du tableau	Sens
Characteristics	Nom de la variable
Type	`double`, `integer` (quantitatives), `character` ou `categorical` (qualitatives)
Unique	Nombre de modalités d'une variable qualitative
Modality	Nom de chaque modalité
Missing	Nombre de valeurs manquantes
N	Nombre de valeurs renseignées
mean (SD) / (%)	Moyenne (écart-type) d'une variable quantitative ; pourcentage d'une modalité

Visites ou patients ?

Au format long, ces statistiques portent sur les *visites* : un patient vu dix fois pèse dix fois plus. Pour une caractéristique fixe (âge, sexe), compter par patient, par exemple avec l'option `patients` des diagrammes en barres (section 3.5).

3.4 Exporter les données et les tableaux

Export clean exporte les données nettoyées et filtrées, telles qu'elles seront analysées. **Export stat** exporte la fiche descriptive en Excel (mise en forme conservée), en Word ou en CSV.

3.5 Graphiques descriptifs (Plots)

Dans le panneau **Plots** : cocher un type dans la liste **Graphiques**, puis une variable dans **Response variables**, régler ses paramètres, et cliquer sur **Plot**. Plusieurs variables d'un même type sont tracées les unes sous les autres.

Graphique	Ce qu'il montre	Paramètres principaux
Trajectory	Trajectoires individuelles de la réponse en fonction du délai	Titre, noms des axes, variable de groupe, bornes de classes (*breaks*), libellés, titre de légende, couleur, épaisseur des lignes
Box plot	Distribution d'une variable, éventuellement par classes d'une variable X	Variable X, bornes et libellés des classes de X, variable de groupe
Bar plot	Fréquences des modalités d'une variable	Noms des axes, bornes et libellés pour une variable quantitative, couleur, comptage par ligne (`rows`) ou par patient (`patients`)
Histogram	Distribution d'une variable quantitative	Nombre de classes (règle de Sturges par défaut), échelle : effectif, fréquence (%) ou densité

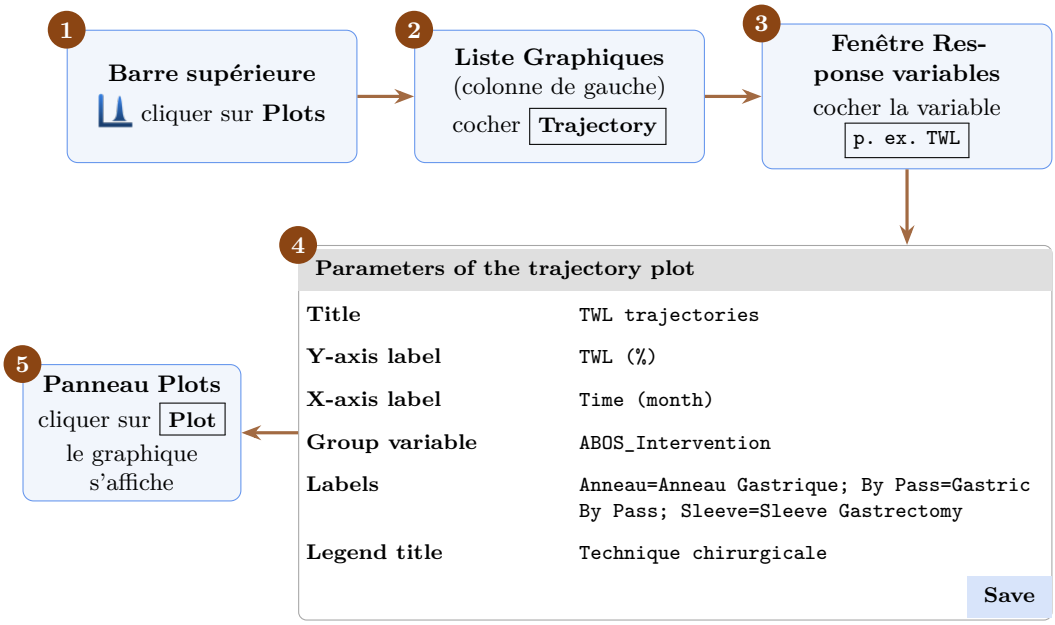
Bornes de classes séparées par des virgules (`-Inf, 40, 50, Inf`), libellés par des points-virgules (`< 40; 40-50; >= 50`). Les classes sont fermées à gauche, $[a, b)$, pour la variable de groupe des trajectoires, et à droite, $(a, b]$, pour les boîtes à moustaches et les diagrammes en barres.

Exemples commentés

Les quatre graphiques suivants portent sur l'échantillon analysé : 1 438 patients et 8 708 mesures, après suppression des 5 patients au statut tabagique manquant (annexe, section A.2).

Chaque schéma numérote les clics ; l'étape 4 donne les valeurs saisies. Un champ absent garde sa valeur par défaut ; un champ vide reçoit la valeur automatique indiquée sous le champ.

Trajectoires individuelles (Trajectory).



La figure 5 montre la TWL de chaque patient en fonction du délai post-opératoire, à raison d'une ligne par patient, colorée selon la technique chirurgicale.

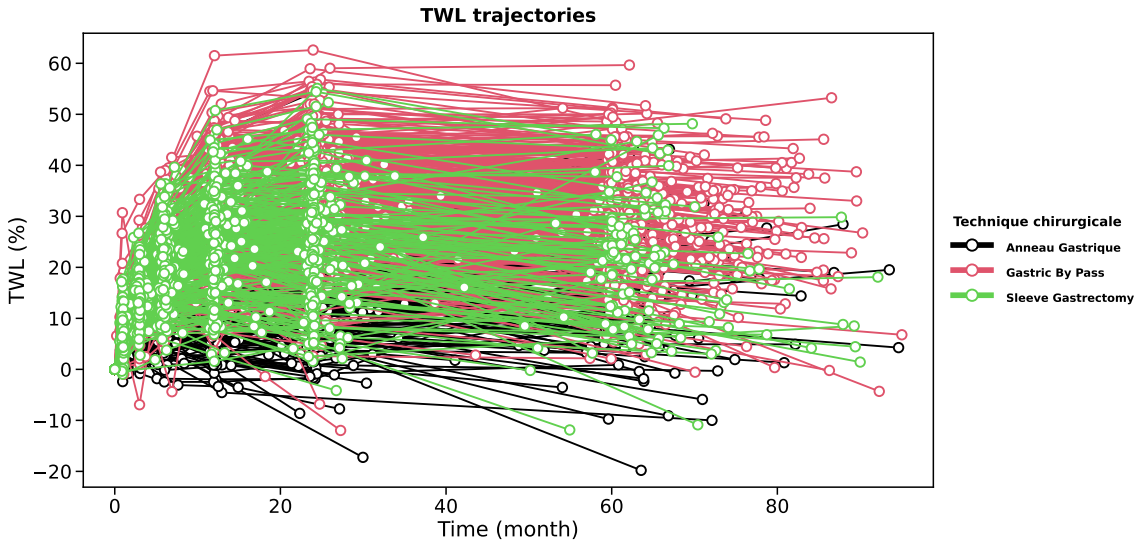
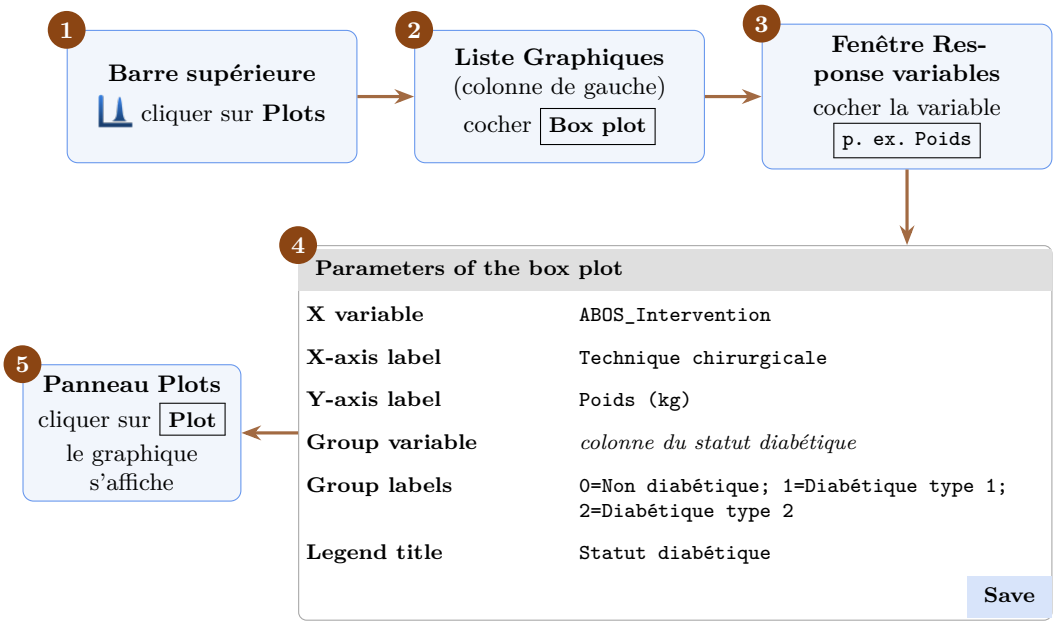


Figure 5 – Trajectoires individuelles de la TWL (%) selon la technique chirurgicale (Anneau Gastrique, Gastric By Pass, Sleeve Gastrectomy).

Les mesures se concentrent autour des visites programmées (3, 6, 12, 24 et 60 mois), à quelques semaines près. Entre 24 et 60 mois, elles sont plus rares (tableau 12) ; au-delà de la visite de 60 mois, elles se raréfient encore avec les perdus de vue. Les trajectoires « Gastric By Pass » sont globalement au-dessus des « Anneau Gastrique », les « Sleeve Gastrectomy » entre les deux ;

lecture qualitative, non ajustée. Les valeurs négatives signalent un poids supérieur au poids préopératoire. Pour limiter la superposition des tracés : option **TN** (section 8.2) ou filtrage par technique.

Boîtes à moustaches (Box plot).



La figure 6 montre le poids selon la technique chirurgicale (variable X) et le statut diabétique (variable de groupe). **Group labels** remplace les codes 0, 1, 2 par des libellés et fixe l'ordre de la légende. Dans la colonne de droite, le bloc **Mean point** (affiché seulement pour les boîtes à moustaches) ajoute la moyenne de chaque distribution : cocher **View point**, puis choisir la couleur (**Color** : `red` par défaut) et la taille des points (**Point size** : 6 par défaut) ; le graphique est retracé aussitôt.

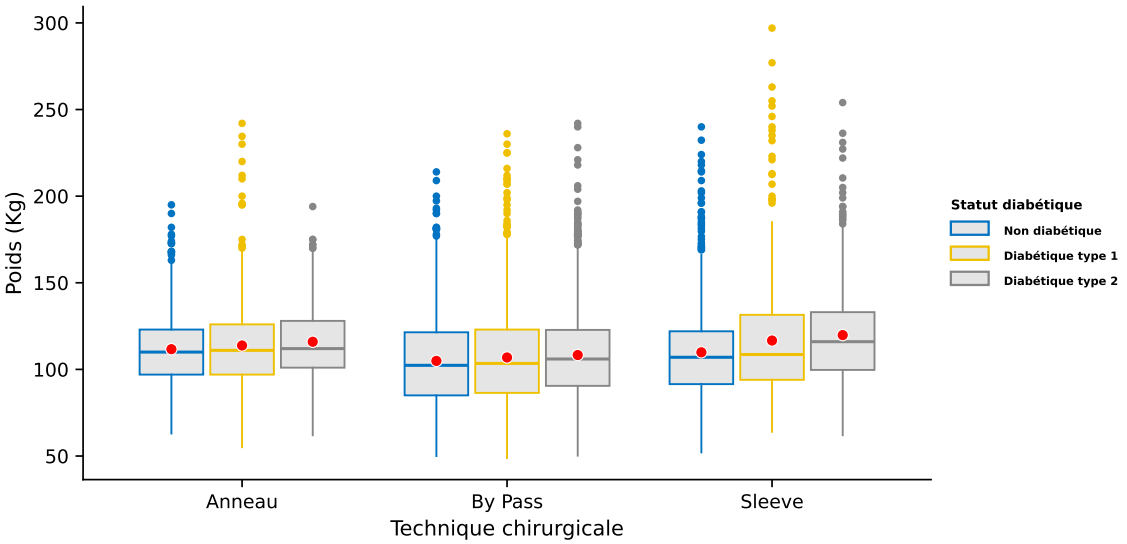


Figure 6 – Distribution du Poids (kg) selon la technique chirurgicale (Anneau = Anneau Gastrique, By Pass = Gastric By Pass, Sleeve = Sleeve Gastrectomy) et le statut diabétique (Non diabétique, Diabétique type 1, Diabétique type 2). Points rouges : moyennes (bloc **Mean point**).

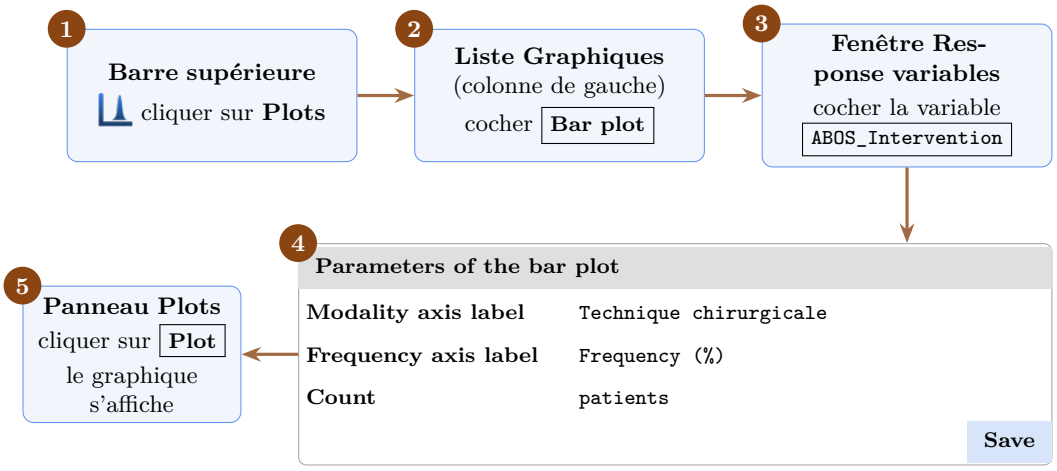
La boîte va du premier au troisième quartile, le trait marque la médiane ; les moustaches s'arrêtent à 1.5 écart interquartile du bord de la boîte, et les points de la couleur de la boîte au-delà sont atypiques. Le point rouge marque la moyenne.

Les médianes sont proches, entre 100 et 115 kg environ. Celle des diabétiques de type 2 est un peu plus haute, surtout pour la Sleeve ; le « By Pass » a des valeurs centrales un peu plus basses. Pour la Sleeve, le groupe « Diabétique type 1 » est plus dispersé et contient le maximum de l'échantillon, proche de 300 kg. Ces écarts restent faibles devant la dispersion intra-groupe.

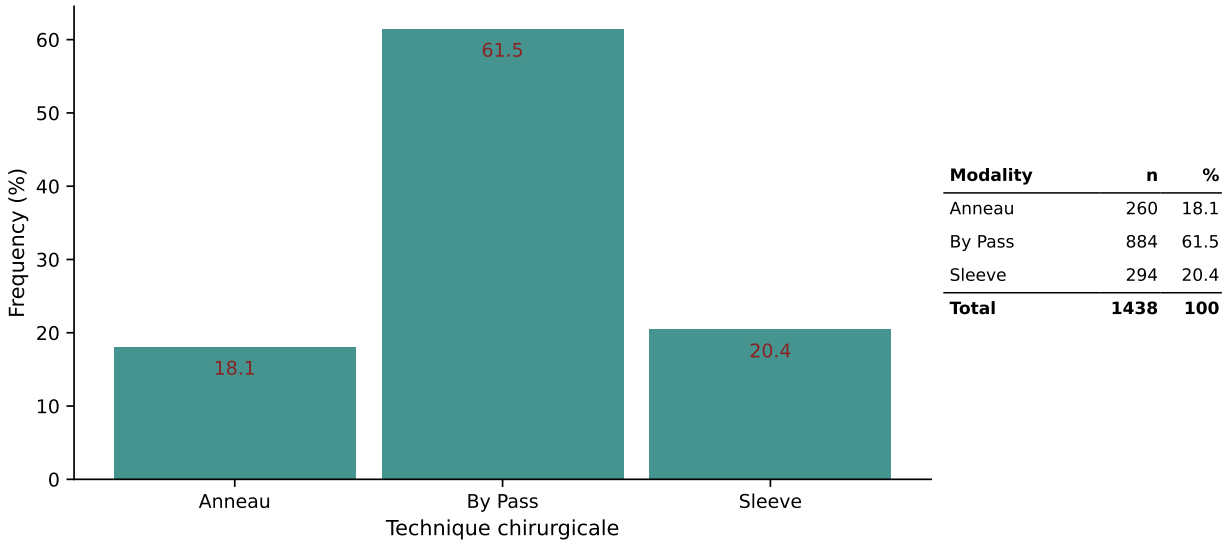
Dans chaque boîte, la moyenne (point rouge) est située au-dessus de la médiane, de quelques kilogrammes : les valeurs élevées tirent la moyenne vers le haut, signe d'une distribution asymétrique à droite (voir aussi l'histogramme, figure 8). La médiane résume donc mieux le poids typique de chaque groupe ; l'écart entre moyenne et médiane, le plus marqué pour les diabétiques de type 1 opérés d'une Sleeve, signale les groupes où les valeurs extrêmes pèsent le plus.

En obésité sévère, la queue droite est attendue : une valeur atypique n'est pas forcément une erreur, mais les plus extrêmes se vérifient. Surtout, chaque boîte mêle mesures pré- et post-opératoires de patients à des stades différents du suivi. Comparer techniques ou statuts diabétiques exige un délai fixé (poids pré-opératoire, poids à 12 mois), obtenu par filtrage (section 3.2). Les effectifs sont des mesures, pas des patients.

Diagramme en barres (Bar plot).



La figure 7 montre la répartition des patients entre les trois techniques chirurgicales.



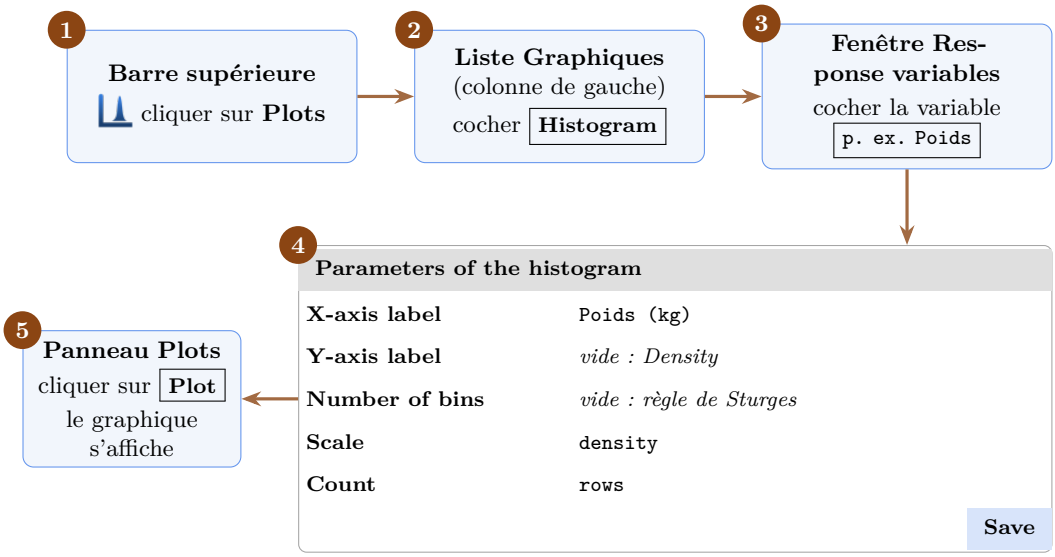
Modality	n	%
Anneau	260	18.1
By Pass	884	61.5
Sleeve	294	20.4
Total	**1438**	**100**

Figure 7 – Répartition des techniques chirurgicales (Anneau = Anneau Gastrique, By Pass = Gastric By Pass, Sleeve = Sleeve Gastrectomy), comptée par patient (option `patients`).

Avec l'option `patients`, chaque patient compte une fois (première valeur renseignée). Sur 1 438 patients : 884 « Gastric By Pass » (61.5 %), 294 « Sleeve Gastrectomy » (20.4 %), 260 « Anneau Gastrique » (18.1 %).

Pour une caractéristique fixe, c'est ce comptage qui décrit la population. Par mesure (option `rows`), on obtiendrait 61.9 % pour « Gastric By Pass », 19.1 % pour « Sleeve Gastrectomy » et 18.9 % pour « Anneau Gastrique », sur 8 708 mesures. L'écart vient du nombre moyen de mesures par patient : environ 6.3 (anneau), 6.1 (bypass) et 5.7 (sleeve). Les patients opérés d'une sleeve sont donc suivis moins longtemps ou moins souvent, ce que la distribution des délais par technique permet de vérifier.

Histogramme (Histogram).



La figure 8 montre la distribution du poids en densité, avec la densité lissée et les statistiques descriptives.

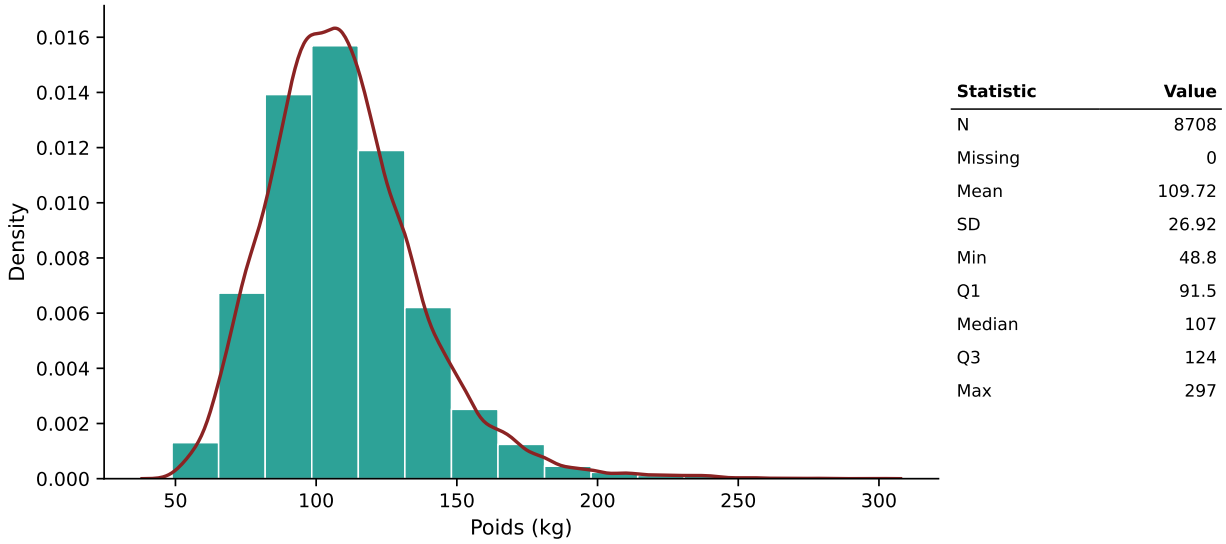


Figure 8 – Distribution du poids (kg) sur l'échantillon analysé (8 708 mesures de 1 438 patients, option `rows`) : histogramme en densité, densité estimée et statistiques descriptives.

Distribution unimodale, asymétrique à droite : moyenne 109.7 kg, médiane 107 kg, sur les 8 708 mesures de l'échantillon analysé. La médiane et l'écart interquartile (91.5 à 124 kg) la résument mieux que la moyenne et l'écart-type (26.9 kg). Les valeurs s'étendent de 48.8 à 297 kg ; le maximum est la valeur proche de 300 kg déjà repérée sur les boîtes à moustaches (figure 6). Sur l'échantillon source (8 734 mesures, tableau 13), la moyenne valait 109.8 kg et le premier quartile 91.6 kg : l'exclusion des 26 mesures au statut tabagique manquant ne modifie pas la distribution. Toutes visites confondues, ces chiffres décrivent le poids au fil du suivi, pas la corpulence à un instant donné.

Graphiques descriptifs et inférence

Ces graphiques décrivent l'échantillon sans rien tester : ils ne suffisent pas à conclure à une différence entre groupes. Ils servent à contrôler les données et à choisir réponse, covariables et fenêtre de suivi avant le clustering.

3.6 Options communes à tous les graphiques

Réglages de la colonne de droite (aucun ne relance de calcul) :

Réglage	Effet
Title option, **Axes option**, **Legend option**	Taille et style de police des titres, des axes et des légendes
Mean point	Boîtes à moustaches seulement : **View point** affiche la moyenne de chaque distribution ; **Color** et **Point size** règlent la couleur et la taille des points
Zoom axes	**Normal** (limites automatiques) ou bornes saisies en **X** et **Y** (minimum et maximum de l'abscisse et de l'ordonnée)
Y-depth	Hauteur, en pixels, de chaque graphique ; commune à tous les graphiques
Sélection d'un graphique	Un clic sur un graphique le sélectionne (fond bleuté) ; un clic hors des graphiques annule la sélection
Curseur vertical, glisser	Zoom et déplacement du graphique sélectionné ; un double-clic rétablit l'affichage d'origine
Survol	Les coordonnées du point de courbe le plus proche s'affichent, avec les titres des axes
Légende	Un clic sur une classe n'affiche que ses éléments ; un second clic les réaffiche tous
Refresh	Retrace le graphique avec les réglages courants
Save plot	Enregistre les graphiques choisis en PNG, PDF, SVG, JPEG, TIFF ou dans un document Word, à la résolution choisie

Les bornes d'axes s'appliquent au graphique sélectionné, ou à tous si aucun ne l'est. Des graphiques à comparer doivent avoir les mêmes bornes.

4. Clustering des trajectoires

4.1 La question clinique et ses difficultés

Deux questions : *combien* de profils d'évolution distincts compte la population, et *à quel* profil appartient chaque patient ? Les données de suivi bariatrique compliquent la tâche :

— les visites sont **éparses** : quelques mesures par patient (sept au plus dans la cohorte ABOS), réparties sur plusieurs années ;

— elles sont **irrégulières** : les délais de suivi diffèrent d'un patient à l'autre ;

— le suivi se **raréfie** : la proportion de patients revus diminue avec le temps ;

— la **variabilité intra-individuelle** (fluctuations, erreur de mesure) se superpose aux différences entre profils.

Un clustering classique des mesures « à 12 mois » ou « à 24 mois » exigerait des visites synchronisées et exclurait beaucoup de patients. AbosCluster traite chaque trajectoire comme une fonction

continue du délai, estimée à partir des visites disponibles, quelle que soit leur date.

4.2 Vue d'ensemble

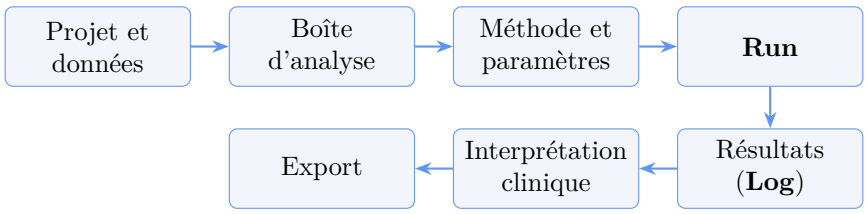


Figure 9 – Les étapes d'un clustering avec AbosCluster. Plusieurs analyses peuvent suivre ce parcours en parallèle dans un même projet, pour être comparées.

4.3 Étape 1 : créer une boîte d'analyse

1. Cliquer sur **Model**, puis sur *Nouvelle analyse* dans la barre gauche.
2. Donner un nom explicite (par exemple « Poids ») et, si on le souhaite, définir une couleur.
3. La boîte apparaît dans le panneau *Clustering sparse longitudinal trajectories*. Elle se déplace à la souris ; le curseur vertical de la barre gauche règle la taille de toutes les boîtes d'analyse.

Associer réponse et méthode dans le nom (« Poids-IM », « TWL-FK ») : complété par `no-cov` ou `with-cov`, il sert de titre aux graphiques des résultats (section 8).

4.4 Étape 2 : choisir la méthode et la configurer

1. Sélectionner la boîte (clic), puis cliquer sur *Configurer*, ou double-cliquer sur la boîte.
2. Choisir la méthode dans la liste : **InfoMergeCluster** (section 5) ou **FKMS** (section 6).
3. La boîte des paramètres s'ouvre (et se rouvre de la même façon). Quatre sections, *Data*, *Model*, *Algorithm* et *Plot*, défilent à la molette ; la poignée en bas à droite l'agrandit.
4. Dans *Data*, choisir l'identifiant (**Identifier**), le temps de suivi (**Time**), la réponse pondérale (**Response**) et cocher les éventuelles covariables (**Covariates**).
5. Valider par **Save**. La configuration est enregistrée et sera exécutée au prochain **Run**.

Changer un paramètre du modèle efface le résultat calculé ; changer une option *Plot* met seulement le graphique à jour.

4.5 Étape 3 : exécuter

Run exécute toutes les analyses configurées, l'une après l'autre ; les boîtes non configurées sont sautées et signalées. L'interface est verrouillée pendant les calculs (section 2.5). Les résultats s'affichent à la fin et restent accessibles par **Log**. *Arrêt* annule les analyses en attente et celle en cours ; les analyses terminées gardent leur résultat.

4.6 Lire une boîte d'analyse

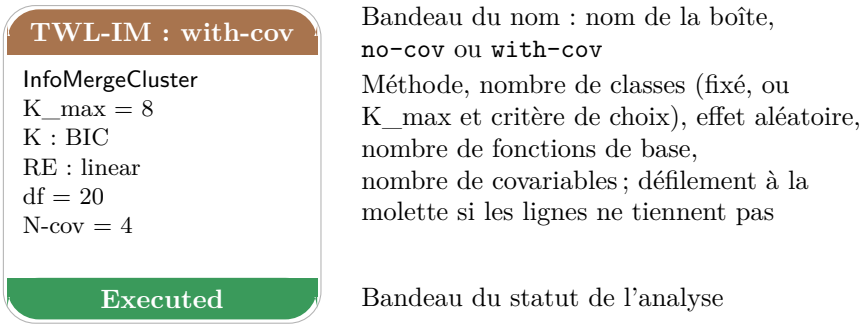


Figure 10 – Image d'une boîte d'analyse configurée et exécutée.

Statut	Signification
Created	Boîte créée ; méthode non choisie ou non configurée
Configured	Paramètres enregistrés ; l'analyse sera exécutée au prochain **Run**
Waiting	En attente dans la file d'exécution
Running	Calcul en cours
Executed	Résultat disponible pour la configuration actuelle

Pour mesurer la concordance des partitions de plusieurs analyses exécutées, les rassembler dans une boîte de comparaison (section 8.3, exemple en section 8.3.4).

4.7 Gérer les boîtes

Supprimer envoie la boîte, configuration et résultat compris, à la corbeille ; *Restaurer* l'en sort ou la supprime définitivement. *Renommer* change le nom d'une boîte sans perdre ses paramètres ni son résultat. Toutes ces actions sont annulables par **Undo**.

Sélection simple et multiple. Clic : sélectionne une boîte (contour bleu). Maj, Ctrl ou Cmd + clic : ajoute ou retire de la sélection. Clic sur le fond : vide la sélection. La sélection multiple sert à placer plusieurs analyses dans une boîte de comparaison (section 8.3). Les commandes de la barre gauche (configuration, suppression, renommage) agissent sur la dernière boîte cliquée.

5. InfoMergeCluster : mélange de modèles linéaires mixtes

InfoMergeCluster est une méthode *probabiliste* : la population est un mélange de K *classes latentes*, chacune avec sa trajectoire moyenne, dont chaque patient s'écarte à sa façon. La méthode estime conjointement trajectoires, proportions et variabilité, et choisit K.

5.1 Modèle

Soit y_{ij} la réponse pondérale (Poids, TWL ou BMI) du patient i ($i = 1, \dots, N$) à sa j-ième visite, au temps t_{ij} ($j = 1, \dots, n_i$). Conditionnellement à l'appartenance du patient à la classe k :

$$y_{ij} = \underbrace{\mathbf{B}(t_{ij})^\top \boldsymbol{\beta}_k}_{\text{trajectoire moyenne}} + \underbrace{\mathbf{x}_{ij}^\top \boldsymbol{\gamma}_k}_{\text{covariables}} + \underbrace{\mathbf{z}(t_{ij})^\top \mathbf{u}_i}_{\text{effet aléatoire}} + \underbrace{\varepsilon_{ij}}_{\text{bruit aléatoire}}, \tag{1}$$

$$\mathbf{u}_i \sim \mathcal{N}_q(\mathbf{0}, \mathbf{G}), \qquad \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2).$$

Terme	Interprétation clinique
$\mathbf{B}(t)^\top \boldsymbol{\beta}_k$	Trajectoire moyenne de la classe k : combinaison de fonctions B-splines cubiques du délai de suivi, assez souple pour décrire une perte rapide, un extremum, un plateau ou une reprise
$\mathbf{x}_{ij}^\top \boldsymbol{\gamma}_k$	Effet des covariables, propre à chaque classe (les covariables sont centrées : la trajectoire moyenne correspond à un patient de caractéristiques moyennes)
$\mathbf{z}(t)^\top \mathbf{u}_i$	Effet aléatoire du patient : écart durable à la trajectoire de sa classe (niveau, pente…), de matrice de covariance $\mathbf{G}$ commune aux classes
ε_{ij}	Bruit aléatoire : fluctuation ponctuelle et erreur de mesure, de variance σ^2
π_k	Proportion de la population appartenant à la classe k

La vraisemblance d'un patient est un mélange (McLachlan et Peel, 2000) de lois normales multivariées, issues de modèles linéaires mixtes (Laird et Ware, 1982) :

$$f(\mathbf{y}_i) = \sum_{k=1}^{K} \pi_k \, \varphi\Big(\mathbf{y}_i;\ \mathbf{X}_i\boldsymbol{\theta}_k,\ \mathbf{Z}_i\mathbf{G}\mathbf{Z}_i^\top + \sigma^2\mathbf{I}_{n_i}\Big), \tag{2}$$

où $\mathbf{X}_i$ et $\mathbf{Z}_i$ empilent les vecteurs $(\mathbf{B}(t_{ij})^\top, \mathbf{x}_{ij}^\top)$ et $\mathbf{z}(t_{ij})^\top$ des n_i visites, et $\boldsymbol{\theta}_k = (\boldsymbol{\beta}_k, \boldsymbol{\gamma}_k)$. Un patient à deux mesures contribue à hauteur de l'information qu'il apporte.

Pourquoi un modèle mixte ?

Sans $\mathbf{z}(t)^\top \mathbf{u}_i$, deux patients d'une même classe ne différeraient que par un bruit indépendant d'une visite à l'autre. Un patient qui perd toujours trois points de plus que sa classe présente un écart *persistant* : le modèle mixte l'attribue à la variabilité individuelle au lieu de créer une classe de plus.

5.2 Trajectoires moyennes : splines pénalisées

La base comporte `df` fonctions B-splines (de Boor, 2001) de degré `degree` (15 et 3 par défaut), à nœuds intérieurs aux quantiles des temps observés (base plus fine là où les visites abondent). La courbure est pénalisée pour ne pas reproduire le bruit (O'Sullivan, 1986; Ruppert et al., 2003) (`penalty`) :

$$\mathrm{pen}(\boldsymbol{\beta}_k) = \lambda\, \boldsymbol{\beta}_k^\top \mathbf{P}\, \boldsymbol{\beta}_k, \qquad P_{jl} = \int B_j^{(m)}(u)\, B_l^{(m)}(u)\, \mathrm{d}u, \tag{3}$$

où $m =$ `pen_order` est l'ordre de la dérivée pénalisée ($m = 2$: courbure). λ est estimé à chaque itération (mise à jour de Fellner–Schall (Wood et Fasiolo, 2017)) ; la complexité de chaque courbe se mesure en degrés de liberté effectifs (*edf*), inférieurs à `df`. Le résultat dépend peu de `df` s'il est assez grand.

5.3 Variabilité individuelle (re)

`re`	Effet aléatoire	Lecture clinique
`intercept`	u_{i0}	Le patient se situe durablement au-dessus ou au-dessous de sa classe, d'un écart constant
`linear` (défaut)	$u_{i0} + u_{i1}t$	L'écart peut aussi se creuser ou se résorber avec le temps
`spline`	combinaison de fonctions de base	L'effet aléatoire peut prendre une forme quelconque

5.4 Lois a priori sur la structure de variance

Pour séparer effet aléatoire (covariance $\mathbf{G}$) et bruit (variance σ^2) malgré peu de visites par patient, InfoMergeCluster utilise des lois a priori faiblement informatives, *calibrées sur les données* par le variogramme empirique (Diggle, 1988) des résidus intra-patient : une loi *inverse-Wishart* ($\mathcal{IW}$) pour la matrice $\mathbf{G}$ et une loi *inverse-gamma* ($\mathcal{IG}$) pour la variance σ^2 :

$$\mathbf{G} \sim \mathcal{IW}(\nu_0, \mathbf{\Psi}_0), \qquad \sigma^2 \sim \mathcal{IG}(a, b), \quad b = (a+1)\,\tau^2, \tag{4}$$

où l'effet de pépite τ^2 (variance des écarts entre deux visites très rapprochées) fixe le mode de σ^2, et la part restante de la variance (le palier moins la pépite) calibre l'échelle $\mathbf{\Psi}_0$ de $\mathbf{G}$. Les paramètres sont estimés par leur mode a posteriori, calculé par un algorithme EM (Dempster et al., 1977) pénalisé.

5.5 Initialisation par micro-classes et fusions

L'EM converge vers un maximum local qui dépend de la partition de départ. Plutôt que de multiplier les départs aléatoires pour chaque K, InfoMergeCluster construit les partitions candidates par fusions successives :

1. **Micro-classes.** Les trajectoires individuelles, résumées par leurs coefficients sur la base de splines, sont réparties par k-means en K_0 micro-classes, avec $K_0 > K_{\max}$ (`K0` ; vide : choix automatique). C'est la seule étape aléatoire de l'algorithme (`nstart` initialisations, graine `seed`).

2. **Fusions.** À chaque étape, les deux classes dont la fusion dégrade le moins le critère pénalisé sont réunies, et le modèle fusionné est réajusté par quelques cycles EM rapides (`quick_cycles`). Une loi a priori de Dirichlet de paramètre `a_dir` sur les proportions π_k stabilise l'estimation des petites classes au cours de ces fusions.

3. **Arbre.** La suite des fusions forme un arbre déterministe, de K_0 classes jusqu'à une seule ; il fournit, pour chaque K examiné, une partition initiale.

4. **Ajustement final.** Pour chaque K retenu, le modèle est ajusté par des cycles EM complets (`full_cycles`, `inner_cap` itérations internes par cycle), jusqu'à la tolérance `tol`. La procédure est répétée au plus `n_outer` fois (itérations externes), en repartant de la meilleure solution obtenue.

Les partitions sont emboîtées : passer de K à $K+1$ classes scinde en général une classe en deux.

5.6 Choix du nombre de classes

`K` vide : le modèle est ajusté pour $K = 1, \ldots, K_{\max}$ et l'on retient le K qui minimise le BIC (Schwarz, 1978) ou l'ICL (Biernacki et al., 2000) :

$$\mathrm{BIC}_K = -2\,\ell_K(\hat{\boldsymbol{\vartheta}}) + d_K \log N, \qquad \mathrm{ICL}_K = \mathrm{BIC}_K + 2\,\mathrm{E}_K, \quad \mathrm{E}_K = -\sum_{i=1}^{N}\sum_{k=1}^{K} \hat{\tau}_{ik} \log \hat{\tau}_{ik}, \tag{5}$$

où ℓ_K est la log-vraisemblance maximisée, $d_K = (K-1) + \mathrm{edf} + q(q+1)/2 + 1 + \mathbb{1}_{\text{penalty}}$ le nombre effectif de paramètres, où edf est la somme des degrés de liberté effectifs des K classes, coefficients des covariables compris (augmenté des coefficients d'appartenance si `weights = "covariates"`), et E_K l'entropie du clustering.

Critère	Ce qu'il privilégie	Quand le préférer
BIC	L'ajustement du modèle aux données, pénalisé par sa complexité	Estimer au mieux la structure de la population
ICL	En outre, des classes *bien séparées* : l'entropie pénalise les patients d'appartenance incertaine	Obtenir des profils cliniquement distincts et des affectations nettes

Une classe d'effectif a posteriori inférieur à `min_size` est supprimée et le modèle réajusté. `K` fixé : pas de sélection ; l'arbre fournit la partition initiale.

Nombre de classes

Le critère indique le K le mieux soutenu par les données, pas que chaque classe soit une entité clinique. Deux classes très proches ou une classe de quelques patients appellent un examen critique ; une solution plus simple, interprétable et stable vaut souvent mieux qu'un léger gain de critère.

5.7 Covariables

Les covariables interviennent :

— **dans la trajectoire** : chaque classe possède ses propres coefficients $\boldsymbol{\gamma}_k$; le clustering porte alors sur la forme de la trajectoire *à covariables égales* ;

— **dans l'appartenance** (`weights = "covariates"`) : la probabilité d'appartenir à chaque classe dépend des caractéristiques du patient, mesurées à l'inclusion, par un modèle logistique multinomial, $\pi_k(\mathbf{w}_i) = \exp(\boldsymbol{\alpha}_k^\top \mathbf{w}_i) / \sum_l \exp(\boldsymbol{\alpha}_l^\top \mathbf{w}_i)$, la classe C1 servant de référence.

5.8 Affectation des patients

Probabilité a posteriori d'appartenance :

$$\hat{\tau}_{ik} = \frac{\hat{\pi}_k \, \varphi_k(\mathbf{y}_i)}{\sum_{l=1}^{K} \hat{\pi}_l \, \varphi_l(\mathbf{y}_i)}. \tag{6}$$

Chaque patient est affecté à la classe la plus probable.

5.9 Paramètres

Paramètre	Défaut	Rôle et conseil
Model		
`K`	3	Nombre de classes ; vide : choix automatique par le critère
`K_max`	8	Nombre maximal de classes examiné en choix automatique
`df`	15	Nombre de fonctions B-splines de la trajectoire moyenne
`degree`	3	Degré des splines (cubiques)
`penalty`	coché	Pénalisation de la courbure ; à conserver
`pen_order`	2	Ordre de la dérivée pénalisée
`re`	`linear`	Structure de l'effet aléatoire (section 5.3)
`weights`	`constant`	`covariates` : appartenance dépendant des covariables
`criterion`	BIC	Critère de choix de K : BIC ou ICL
`min_size`	2	Effectif a posteriori minimal d'une classe

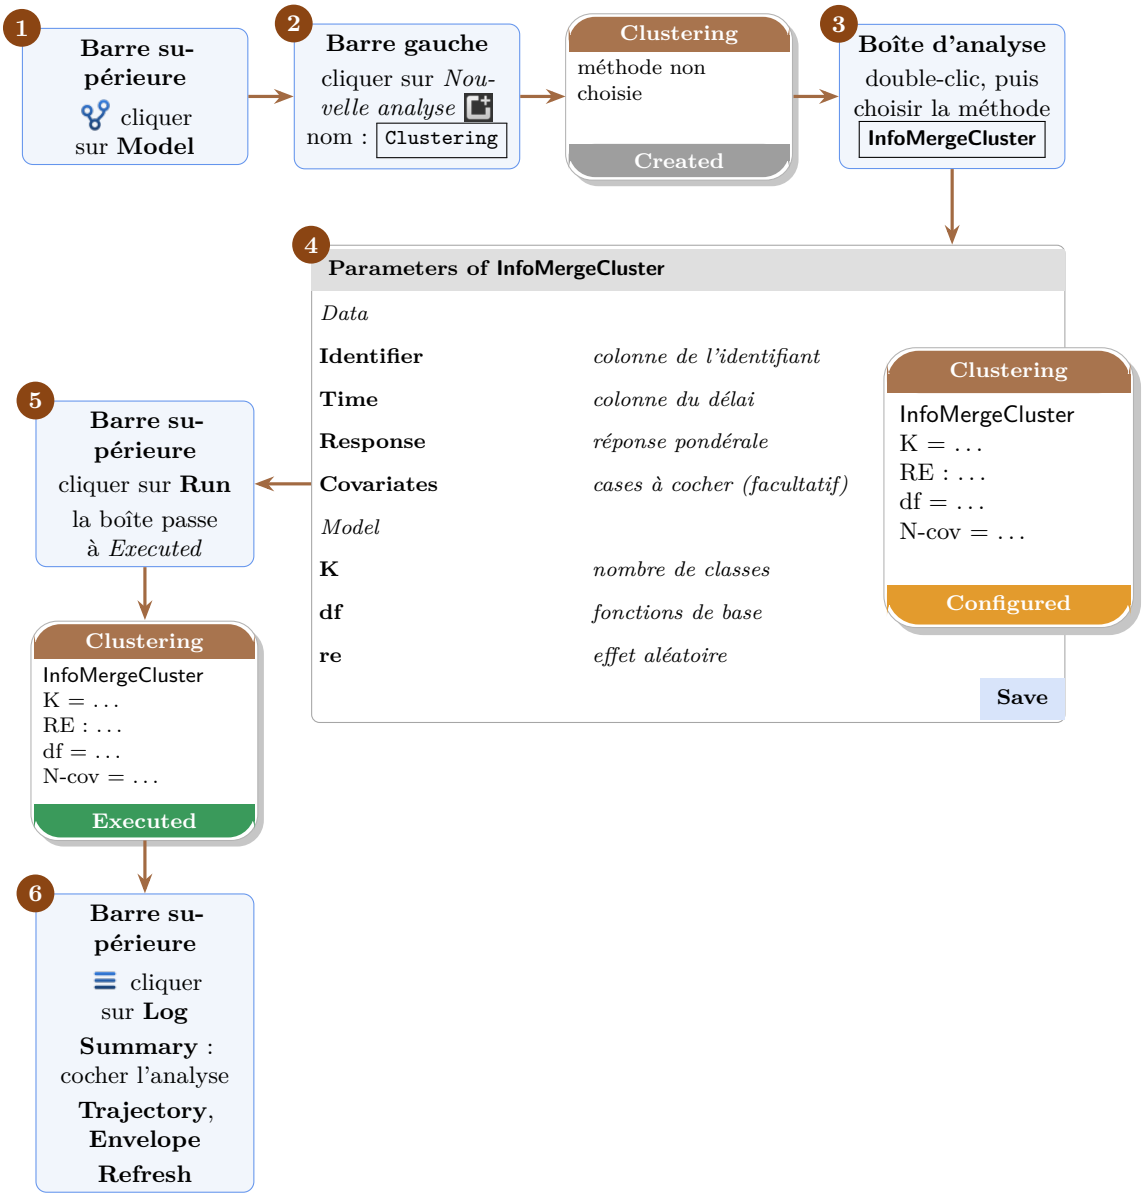
Paramètre	Défaut	Rôle et conseil
`K0`	vide	Nombre de micro-classes de l'initialisation ; vide : automatique
Algorithm		
`a_dir`	0.5	Paramètre de la loi de Dirichlet utilisée lors des fusions
`n_outer`	3	Nombre maximal d'itérations externes
`quick_cycles`, `full_cycles`	4, 15	Cycles EM rapides (exploration) et complets (ajustement final)
`inner_cap`	3	Itérations internes par cycle
`tol`	10^{-5}	Tolérance de convergence
`nstart`	5	Nombre d'initialisations du k-means
`seed`	vide	Graine aléatoire ; la fixer rend le résultat reproductible
Plot		
`envelope`, `level`	non, 0.95	Enveloppe de confiance autour des trajectoires moyennes (section 8.2)
`show_data`, `max_subjects`	oui, 300	Trajectoires individuelles et nombre maximal affiché
`xlab`, `ylab`, `legend`		Titres des axes, légende des classes ; le titre du graphique est le nom de la boîte (section 8)

Reproductibilité

L'initialisation est aléatoire (k-means) : fixer `seed` rend le résultat reproductible. Vérifier que les classes résistent à un changement de graine est un test de stabilité à rapporter.
La graine ne reproduit pas une implémentation R : Mersenne-Twister et `set.seed()` dans R, PCG64 (NumPy) dans AbosCluster ; fonctions de tirage (`sample`, `rmultinom`) et k-means (Hartigan–Wong contre Lloyd avec k-means++ (Arthur et Vassilvitskii, 2007)) diffèrent aussi. Pour comparer les deux, fournir la même partition initiale ou comparer les partitions finales par l'indice de Rand ajusté (section 8.3).

5.10 Clustering avec InfoMergeCluster : comment ça marche ?

Deux analyses avec $K = 3$ imposé : le poids sans covariable, la TWL avec les quatre covariables (âge, technique chirurgicale, statut diabétique, statut tabagique). Le schéma numérote les clics ; les champs non cités gardent leur valeur par défaut (section 5.9).



Valeurs saisies à l'étape 4 (colonnes `Patient` et `Time` pour l'identifiant et le délai ; $K = 3$, `df` $= 20$ et effet aléatoire `linear` dans les deux cas) :

Nom saisi	Response	Covariates	re
Poids-IM	`Poids`	aucune	`linear`
TWL-IM	`TWL`	âge, technique, tabac, diabète	`linear`

Les covariables cochées sont les colonnes `AgeJourIntervention__lcn` (âge, quantitatif), `ABOS_Intervention` (technique chirurgicale, trois modalités), `M000..TabacFumeur` (statut tabagique) et `M000..ABOS_Diabete_Oui__lc` (statut diabétique, trois modalités), codées en indicatrices (première modalité en référence). Un clic sur **Run** exécute les deux analyses.

Afficher les résultats (étape 6). **Log** ouvre les résultats (section 8) : cocher les deux analyses sous **Summary**, puis **Trajectory** et **Envelope** (95 %), **Refresh** ; **Save plot** enregistre.

Résultats : tableau 6 et figure 11.

Réponse	C1	C2	C3
Poids-IM : no-cov	58 %	29 %	12 %
TWL-IM : with-cov	46 %	30 %	24 %

Tableau 6 – Proportions des classes estimées par InfoMergeCluster ($K = 3$) pour le Poids et la TWL (figure 11), arrondies au pourcentage entier. Dans chaque analyse, les classes sont numérotées par proportion décroissante : C1 du Poids et C1 de la TWL ne désignent pas nécessairement les mêmes patients.

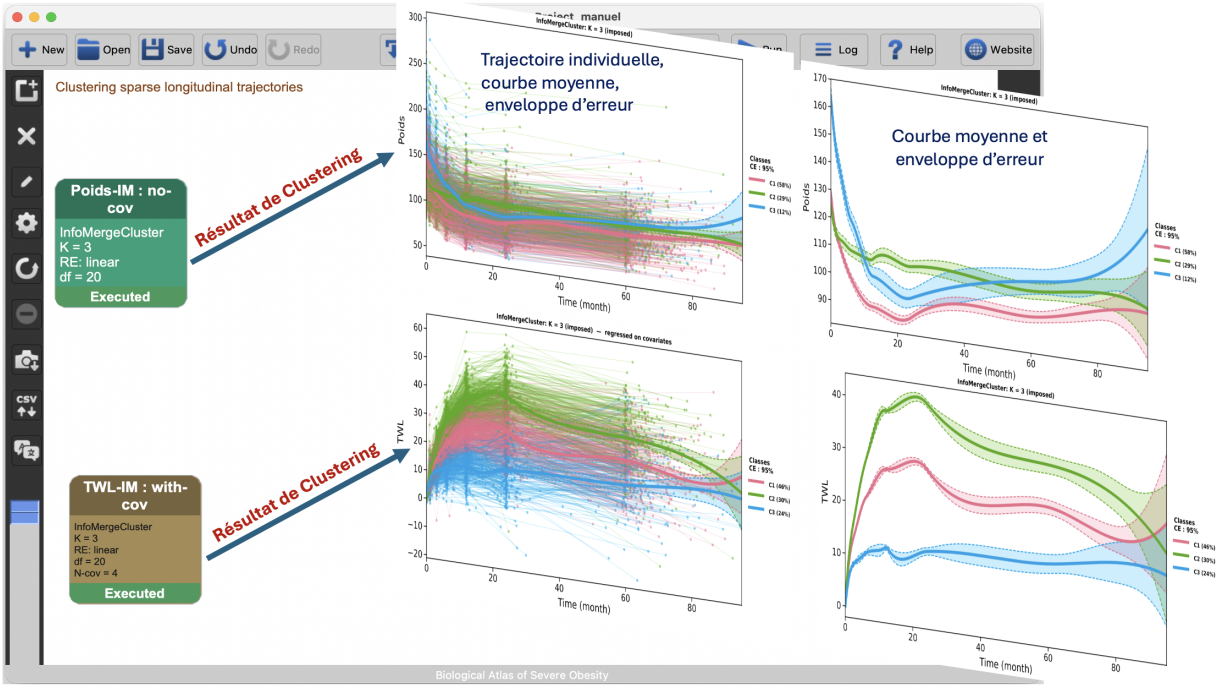


Figure 11 – InfoMergeCluster avec $K = 3$ imposé, effet aléatoire `linear` et `df` $= 20$: analyse « Poids-IM : no-cov » (en haut) et analyse « TWL-IM : with-cov », ajustée sur l'âge à l'intervention, la technique chirurgicale, le statut tabagique et le statut diabétique (en bas). À gauche : trajectoires individuelles, trajectoires moyennes et enveloppes de confiance à 95 % ; à droite : trajectoires moyennes et enveloppes seules.

Poids-IM : no-cov. Les classes diffèrent par le poids initial et par l'évolution.

— **C1 (58 %)**, poids initial de l'ordre de 120 à 130 kg : diminution jusqu'à un minimum de la trajectoire moyenne d'environ 83 kg vers 22 mois, puis stabilisation entre 84 et 88 kg jusqu'à la fin du suivi.

— **C2 (29 %)**, poids initial du même ordre que C1 : perte moins ample, jusqu'à environ 104 kg vers 12 mois, puis décroissance lente, de l'ordre de 100 kg à 30 mois et de 92 kg à 80 mois ; l'écart avec C1 atteint ainsi environ 20 kg dès la première année.

— **C3 (12 %)**, poids initial le plus élevé (environ 165 kg) : perte la plus rapide et la plus ample, environ 75 kg en 22 mois, jusqu'à un minimum voisin de 90 kg, suivie d'une reprise pondérale progressive (environ 96 kg entre 50 et 70 mois). Sa trajectoire croise celle de C2 vers 10 mois, puis vers 45 mois.

Le croisement de C2 et C3 montre que la partition ne se réduit pas au poids initial : c'est la forme de la trajectoire qui décide, grâce à l'effet aléatoire de niveau et de pente (section 7).

TWL-IM : with-cov. Les classes diffèrent par l'ampleur et la tenue de la perte.

— **C2 (30 %)**, *bons répondeurs* : perte la plus importante, environ 38 % dès 10 mois et un maximum d'environ 41 % vers 20 mois ; décroissance ensuite, à environ 34 % à 40 mois et 33 % à 60 mois, puis plus marquée au-delà de 70 mois (environ 28 % à 80 mois).

— **C1 (46 %)**, *répondeurs intermédiaires* : environ 27 % à 12 mois et un maximum d'environ 29 % vers 20 mois, puis perte partielle du bénéfice, avec un plateau voisin de 23 à 24 % entre 40 et 60 mois et une diminution vers 20 % à 80 mois.

— **C3 (24 %)**, *réponse insuffisante* : TWL d'environ 11 % dès 10 mois, puis plateau voisin de 13 % entre 25 et 60 mois, et légère hausse vers 15 à 16 % au-delà, dans une enveloppe large.

Trajectoires sur données brutes, aux valeurs moyennes des covariables de chaque classe ; comparaison avec les données régressées en figure 13.

Les enveloppes, étroites jusqu'à 60 mois environ, s'élargissent ensuite : après 70 mois, peu de patients sont revus et les variations tardives (reprise de C3 pour le Poids, baisse de C2 pour la TWL) sont imprécises. Les deux analyses ne définissent pas les mêmes classes ; leur concordance se mesure en section 8.3.

6. FKMS : k-means fonctionnel

FKMS (*functional k-means*) cherche la partition qui rapproche le plus chaque trajectoire de la courbe moyenne de sa classe.

6.1 Principe

La courbe moyenne de la classe k est $\mu_k(t) = \mathbf{S}(t)^\top \boldsymbol{\beta}_k$, où $\mathbf{S}(t)$ est une base de `N.bs` fonctions (B-splines cubiques ou base de Fourier). FKMS minimise

$$\sum_{i=1}^{N} \sum_{j=1}^{n_i} w_{ij} \left(y_{ij} - \mathbf{S}(t_{ij})^\top \boldsymbol{\beta}_{c_i} - \mathbf{x}_{ij}^\top \boldsymbol{\gamma}_{c_i} \right)^2, \qquad w_{ij} = \frac{1}{n_i}, \tag{7}$$

en alternant, comme l'algorithme de Lloyd (Lloyd, 1982), deux étapes jusqu'à stabilité :

1. **estimation** : pour une partition donnée, les coefficients de chaque classe sont obtenus par moindres carrés pondérés pénalisés, $\hat{\boldsymbol{\theta}}_k = (\mathbf{D}_k^\top \mathbf{W}_k \mathbf{D}_k + \lambda_k \mathbf{P})^{-1} \mathbf{D}_k^\top \mathbf{W}_k \mathbf{y}_k$;
2. **affectation** : chaque patient rejoint la classe dont la courbe minimise la somme de ses écarts quadratiques.

Le poids $1/n_i$ donne à chaque patient la même influence. On garde, sur `N.random` départs aléatoires, la solution d'erreur quadratique moyenne (MSE) minimale.

6.2 Lissage et choix de λ par validation croisée généralisée

En base B-spline, la courbure est pénalisée comme en section 5.2. Cocher `lambda.gcv` ouvre **Grid of lambda values (GCV)** : **Lower bound**, **Upper bound** et **Number of values** définissent une grille log-régulière (par défaut 30 valeurs de 10^{-6} à 10^{3}). On retient le λ qui minimise la validation croisée généralisée (Craven et Wahba, 1979) :

$$\mathrm{GCV}(\lambda) = \frac{n \, \mathrm{RSS}_w(\lambda)}{\left(n - \operatorname{tr} \mathbf{H}_\lambda\right)^2}, \tag{8}$$

où RSS_w est la somme pondérée des carrés des résidus et $\operatorname{tr} \mathbf{H}_\lambda$ le nombre effectif de paramètres. λ est propre à chaque classe, ou commun si `lambda.common` est coché ; sans `lambda.gcv`, la valeur

`lambda` est appliquée telle quelle. Annuler la boîte de la grille décoche `lambda.gcv` ; décocher puis recocher permet de modifier la grille, rappelée dans la boîte d'analyse (par exemple `grid: [100, 1000]` × `10`).

Choix de la grille de λ

Le λ optimal dépend de l'unité de temps, de `N.bs` et de l'échelle de la réponse (kg ou %). S'il tombe sur une borne de la grille, élargir la grille et relancer. Le λ de chaque classe figure dans l'export (section 8.4).

6.3 Covariables, enveloppes et nombre de classes

— `cov.effect = "cluster"` : effet des covariables propre à chaque classe ; `"common"` : effet commun pendant la recherche de la partition, puis ajustement final propre à chaque classe.

— `conf.band` : calcul de la covariance des coefficients de chaque classe, nécessaire à l'enveloppe de confiance (section 8).

— `se.type` : estimateur de cette covariance, `sandwich` ou `model` (ci-dessous).

— `K` vide : FKMS est exécuté pour $K = 1, \ldots, K_{\max}$ et le K de MSE minimale est retenu ; ce choix automatique est déconseillé (remarque ci-dessous).

Estimateur de la covariance (`se.type`). Notons $\mathbf{A}_k = \mathbf{D}_k^\top \mathbf{W}_k \mathbf{D}_k + \lambda_k \mathbf{P}$ et $\hat{r}_{ij}$ les résidus de la classe k. L'estimateur `sandwich` (Liang et Zeger, 1986), retenu par défaut, regroupe les scores par patient :

$$\hat{\mathbf{V}}_k = \mathbf{A}_k^{-1} \Big(\tfrac{N_k}{N_k - 1} \sum_{i \in k} \mathbf{U}_i \mathbf{U}_i^\top \Big) \mathbf{A}_k^{-1}, \qquad \mathbf{U}_i = \sum_{j=1}^{n_i} w_{ij}\, \hat{r}_{ij}\, \mathbf{d}_{ij}, \tag{9}$$

où $\mathbf{d}_{ij}$ est la ligne du plan d'expérience (fonctions de base et covariables) de la visite j du patient i et N_k le nombre de patients de la classe k. Il reste valide quelle que soit la corrélation intra-patient. L'estimateur `model` suppose des erreurs indépendantes et homoscédastiques, $\hat{\mathbf{V}}_k = \hat{\sigma}_k^2\, \mathbf{A}_k^{-1} \mathbf{D}_k^\top \mathbf{W}_k^2 \mathbf{D}_k \mathbf{A}_k^{-1}$; avec des mesures répétées, il sous-estime l'incertitude.

La MSE comme critère de choix de K

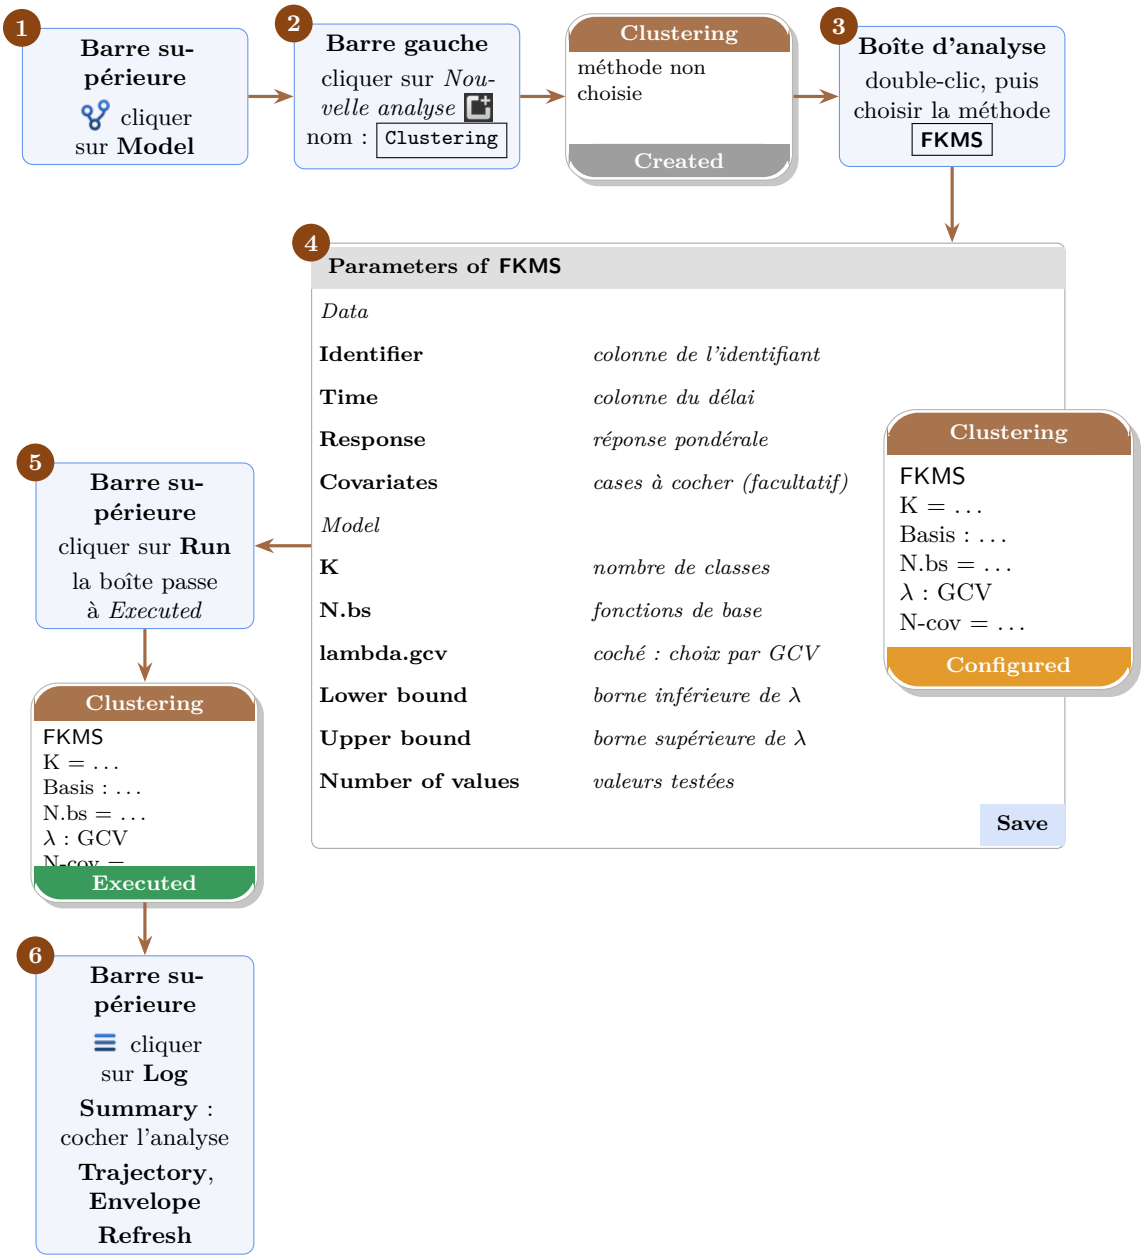
La MSE décroît quand K augmente : le « K de MSE minimale » est presque toujours $K_{\max}$, ce qui n'est pas une sélection. Fixer K sur des bases cliniques ou reprendre celui d'InfoMergeCluster (BIC ou ICL), puis comparer les partitions (section 8.3). Le « coude » de la courbe MSE en fonction de K n'est qu'un repère informel.

Paramètre	Défaut	Rôle
`K`, `K_max`	3, 8	Nombre de classes (vide : MSE minimale, soit en pratique $K_{\max}$; déconseillé) ; borne du choix automatique
`N.bs`	8	Nombre de fonctions de base (au moins 4 en B-spline, 3 en Fourier)
`basis`	B	`B` : B-splines cubiques ; `F` : base de Fourier
`lambda`, `lambda.gcv`, `lambda.common`	0, oui, non	Lissage fixe, choisi par GCV, propre à chaque classe ou commun

Paramètre	**Défaut**	**Rôle**
Grille de λ (**Lower bound**, **Upper bound**, **Number of values**)	10^{-6}, 10^{3}, 30	Valeurs de λ testées par GCV, espacées logarithmiquement ; saisies en cochant `lambda.gcv`
`cov.effect`	`cluster`	Effet des covariables propre aux classes ou commun
`conf.band`, `se.type`	oui, `sandwich`	Calcul de la covariance des coefficients et estimateur (enveloppe de confiance ponctuelle)
`N.random`, `N.rep`, `seed`	10, 100, vide	Initialisations aléatoires, itérations maximales, graine

6.4 Clustering avec FKMS : comment ça marche ?

Mêmes analyses qu'en section 5.10, avec FKMS : « Poids-FK » (sans covariable) et « TWL-FK » (quatre covariables), $K = 3$, $N.bs = 20$ B-splines, λ par GCV sur 10 valeurs entre 100 et 1000. Champs non cités : valeur par défaut (section 6.3).



Les champs de la grille n'apparaissent qu'une fois `lambda.gcv` coché. `basis` = `B`. L'affichage se règle comme en section 5.10.

Résultats : tableau 8 et figure 12.

Réponse	C1	C2	C3
Poids-FK : no-cov	46 %	42 %	12 %
TWL-FK : with-cov	43 %	31 %	26 %

Tableau 8 – Proportions des classes estimées par FKMS ($K = 3$) pour le Poids et la TWL (figure 12), arrondies au pourcentage entier. Dans chaque analyse, les classes sont numérotées par effectif décroissant.

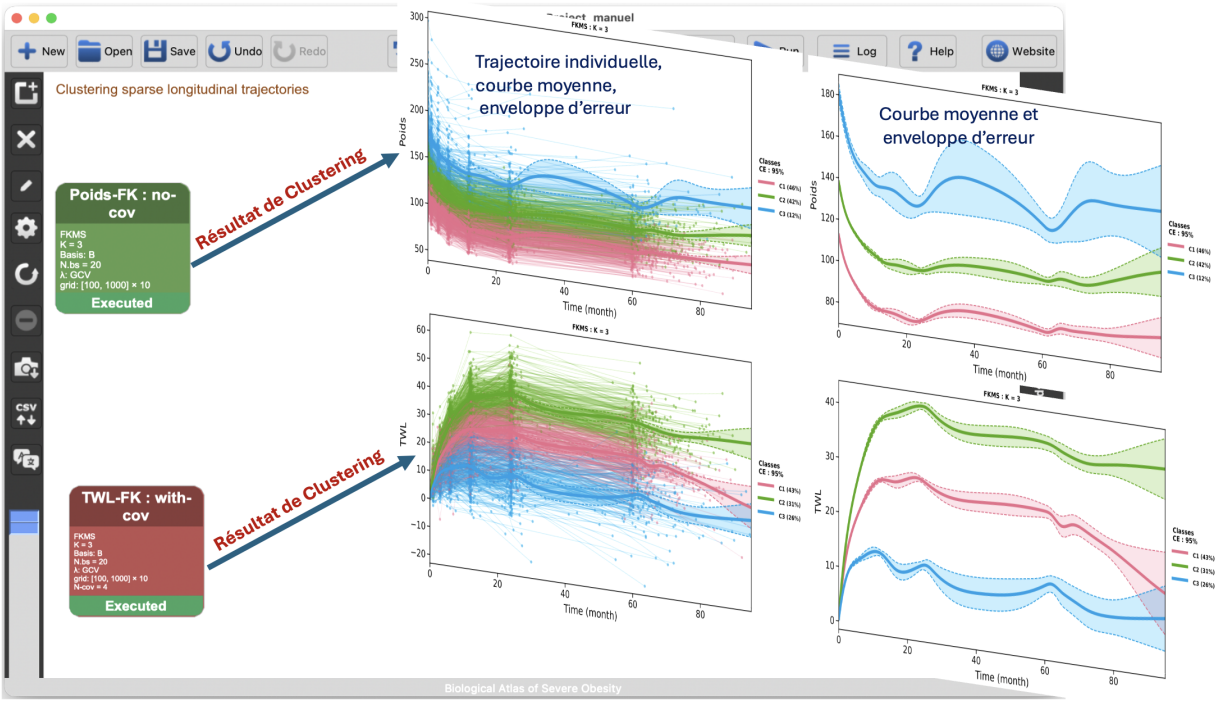


Figure 12 – FKMS avec $K = 3$ imposé : analyse « Poids-FK : no-cov » (en haut) et analyse « TWL-FK : with-cov », ajustée sur l'âge à l'intervention, la technique chirurgicale, le statut tabagique et le statut diabétique (en bas), toutes deux avec $N.bs = 20$ et λ choisi par GCV sur une grille de 10 valeurs comprises entre 100 et 1000, régulièrement espacées en échelle logarithmique. À gauche : trajectoires individuelles, trajectoires moyennes et enveloppes de confiance ponctuelles à 95 % (estimateur `sandwich`) ; à droite : trajectoires moyennes et enveloppes seules.

Poids-FK : no-cov. Classes ordonnées par le poids initial, sans croisement.

— **C1 (46 %)**, poids initial le plus bas (environ 112 kg) : diminution jusqu'à environ 76 kg à 12 mois et 71 kg vers 22 mois, puis décroissance lente, voisine de 65 kg au-delà de 60 mois.

— **C2 (42 %)**, poids initial intermédiaire (environ 138 kg) : diminution jusqu'à environ 100 kg à 12 mois, puis valeurs comprises entre 88 et 97 kg jusqu'à la fin du suivi.

— **C3 (12 %)**, poids initial le plus élevé (environ 180 kg) : diminution jusqu'à environ 127 kg vers 22 mois, puis trajectoire irrégulière, comprise entre 115 et 140 kg. L'enveloppe, large dès 25 mois, montre que ces variations ne sont pas établies (petit effectif, visites tardives rares).

TWL-FK : with-cov. Même hiérarchie qu'avec InfoMergeCluster.

— **C2 (31 %)**, *bons répondeurs* : environ 37 % à 12 mois, maximum d'environ 39 % entre 20 et 25 mois, puis décroissance lente, à environ 34 % à 40 mois, 32 % à 60 mois et 28 % au-delà de 75 mois.

— **C1 (43 %)**, *répondeurs intermédiaires* : environ 26 % entre 12 et 24 mois, puis diminution progressive, à environ 21 % entre 40 et 60 mois, plus marquée au-delà de 65 mois.

— **C3 (26 %)**, *réponse insuffisante* : maximum d'environ 12 % vers 10 mois, puis diminution, à environ 5 % entre 40 et 55 mois et voisine de 0 % au-delà de 75 mois, soit un retour au poids pré-opératoire.

Les enveloppes s'élargissent en fin de suivi : prudence au-delà de 70 mois.

Comparaison avec InfoMergeCluster. TWL : mêmes trois profils, proportions proches (43, 31, 26 % avec FKMS ; 46, 30, 24 % avec InfoMergeCluster). Les trajectoires moyennes concordent jusqu'à 24 mois environ. Ensuite, les bons répondeurs restent proches (environ 33 % à 60 mois avec InfoMergeCluster, 32 % avec FKMS), de même que les répondeurs intermédiaires (environ 23 à 24 % contre 21 % entre 40 et 60 mois). La différence porte sur la réponse insuffisante : elle se maintient vers 13 % avec InfoMergeCluster, mais descend vers 5 % entre 40 et 55 mois avec FKMS, puis vers 0 % au-delà de 75 mois. Cet écart apparaît dès 40 mois, alors que l'enveloppe d'InfoMergeCluster est encore étroite ; il ne tient donc pas seulement à l'imprécision du suivi tardif. Au-delà de 70 mois, en revanche, les enveloppes s'élargissent et les écarts entre méthodes sont peu interprétables. Poids : les partitions divergent (46, 42, 12 % contre 58, 29, 12 %). FKMS ordonne les classes par poids initial ; InfoMergeCluster sépare deux classes de poids initial voisin par l'ampleur de la perte. Faute d'effet aléatoire, FKMS regroupe selon le niveau quand celui-ci domine la variabilité, comme pour le poids absolu (section 7). Des proportions voisines ne prouvent pas que les mêmes patients sont regroupés : voir l'ARI et l'indice de Jaccard (section 8.3).

7. InfoMergeCluster vs FKMS

Le tableau 9 résume les différences.

Tableau 9 – Caractéristiques des deux méthodes, telles qu'utilisées dans cette étude.

	InfoMergeCluster	FKMS
Famille	mélange (vraisemblance pénalisée)	partition (type k-means)
Trajectoire moyenne de classe	B-splines pénalisées, λ estimé par Fellner–Schall	B-splines, moindres carrés pondérés pénalisés, λ choisi par GCV
Dimension de la base	`df` ; nœuds aux quantiles de l'ensemble des mesures, nœuds confondus éliminés (dimension effective $\leq$ `df`)	`N.bs` ; nœuds aux quantiles des instants de mesure distincts, sans élimination (dimension égale à `N.bs`)
Variabilité individuelle	effet aléatoire (ordonnée à l'origine, linéaire ou spline)	non modélisée
Erreur de mesure	σ^2 estimé (loi a priori calibrée par variogramme)	implicite (perte quadratique)
Covariables	effets $\boldsymbol{\gamma}_k$ propres à la classe, non pénalisés	effets $\boldsymbol{\gamma}_k$ propres à la classe, non pénalisés
Affectation	probabiliste (τ_{ik}), puis classe de probabilité maximale	déterministe (centre le plus proche)
Nombre de classes	imposé, ou choisi par BIC ou ICL	imposé, ou choisi par la MSE minimale (déconseillé, section 6.3)
Initialisation	micro-classes par k-means (aléatoire, `seed`), puis arbre de fusions déterministe	affectations aléatoires, meilleure partition retenue
Enveloppe de confiance	ponctuelle ; covariance $\mathbf{H}_k^{-1}$ issue du modèle (information de Fisher pénalisée)	ponctuelle ; covariance `sandwich` par patient (défaut) ou `model`

Différence essentielle. Les deux méthodes estiment une trajectoire moyenne par classe, mais traitent différemment la variabilité intra-classe. InfoMergeCluster la modélise (effet aléatoire $\boldsymbol{u}_i$, erreur $\boldsymbol{\varepsilon}_i$) : l'affectation dépend surtout de la *forme* de la trajectoire. FKMS la compte comme erreur quadratique : tout écart de niveau pèse, et les patients sont regroupés par niveau quand

celui-ci domine.

8. Lire, comparer et exporter les résultats

8.1 Le panneau des résultats

Après **Run**, ou via **Log** : un graphique par analyse exécutée, avec trajectoires individuelles colorées par classe, trajectoires moyennes et légende (« C1 (46%) »). Le titre est le nom de la boîte suivi de `no-cov` ou `with-cov`.

La liste **Summary** choisit les analyses affichées :

— **All analyses**, coché par défaut, affiche toutes les analyses ;

— les autres cases désignent chaque analyse par méthode et réponse (« InfoMergeCluster : TWL »), comme les colonnes **Model 1** et **Model 2** des résultats de comparaison ; deux analyses de même méthode et réponse sont distinguées par le nom de leur boîte, ajouté entre parenthèses ;

— cocher une analyse n'affiche qu'elle, en cocher d'autres les ajoute, et décocher la dernière ramène à **All analyses**.

Avec au moins une boîte de comparaison, la case **Comparisons** affiche les indices de concordance (section 8.3).

8.2 Options propres à chaque graphique

Ces options s'appliquent au graphique sélectionné et sont mémorisées par analyse. Le graphique est retracé sans réestimation, à la même position de défilement.

Option	Effet
Trajectory	Affiche les trajectoires individuelles ; **All** les montre toutes, **TN** en fixe le nombre (tirage reproductible)
Envelope	Affiche l'enveloppe des trajectoires moyennes ; la légende indique son niveau, « CE : 95% »
Regressed data	Pour un modèle avec covariables : données et trajectoires régressées sur les covariables (ci-dessous)
Comparisons	Présente si une boîte de comparaison existe : affiche, dans une boîte déplaçable, l'indice de Rand ajusté et l'indice de Jaccard des paires d'analyses comparées

Enveloppe de confiance. Les deux méthodes produisent une enveloppe de confiance (CE) *ponctuelle* de la *trajectoire moyenne* :

$$\text{CE} : \hat{\mu}_k(t) \pm z_{1-\alpha/2}\sqrt{\mathbf{a}(t)^\top \hat{\mathbf{V}}_k\, \mathbf{a}(t)}, \qquad 1-\alpha = \texttt{level}, \tag{10}$$

où $\mathbf{a}(t)$ réunit les fonctions de base au délai t et, avec covariables, les valeurs de celles-ci retenues pour la représentation (ci-dessous), $z_{1-\alpha/2}$ est le quantile de la loi normale centrée réduite (1.96 pour $\texttt{level} = 0.95$) et $\hat{\mathbf{V}}_k$ la covariance estimée des coefficients, seul élément qui diffère :

— **InfoMergeCluster** : $\hat{\mathbf{V}}_k = \mathbf{H}_k^{-1}$, avec $\mathbf{H}_k = \sum_i \hat{\tau}_{ik}\, \mathbf{X}_i^\top \mathbf{V}_i^{-1} \mathbf{X}_i + \hat{\lambda}\mathbf{P}$ et $\mathbf{V}_i = \mathbf{Z}_i \hat{\mathbf{G}} \mathbf{Z}_i^\top + \hat{\sigma}^2 \mathbf{I}_{n_i}$: information de Fisher pénalisée, pondérée par les probabilités a posteriori d'appartenance. L'effet aléatoire prend en compte la corrélation intra-patient.

— **FKMS** : estimateur `sandwich` par patient (défaut) ou `model` (section 6.3).

À 95 %, elle couvre la trajectoire moyenne à chaque délai pris séparément, pas sur tout le suivi simultanément.

Lire une enveloppe de confiance

Deux enveloppes disjointes sur une période signalent des trajectoires moyennes nettement différentes. L'enveloppe porte sur la courbe moyenne, pas sur la dispersion des patients. Elle est *conditionnelle* (partition, variances et lissage tenus pour connus, incertitude d'affectation ignorée), donc probablement trop étroite, surtout pour les petites classes.

Données brutes et données régressées. Avec covariables, deux représentations :

— **données brutes** : mesures pondérales telles qu'elles ont été observées ; la trajectoire de chaque classe est calculée aux valeurs moyennes des covariables *de cette classe*, $\mathbf{B}(t)^\top \hat{\boldsymbol{\beta}}_k + \bar{\mathbf{x}}_k^\top \hat{\boldsymbol{\gamma}}_k$, et passe au milieu des trajectoires de ses patients ;

— **données régressées** : l'effet des covariables est retiré, $y_{ij}^{\text{reg}} = y_{ij} - (\mathbf{x}_{ij} - \bar{\mathbf{x}})^\top \hat{\boldsymbol{\gamma}}_{c_i}$, ce qui ramène chaque patient aux valeurs moyennes des covariables de l'ensemble de l'échantillon ; les trajectoires sont recalculées en conséquence.

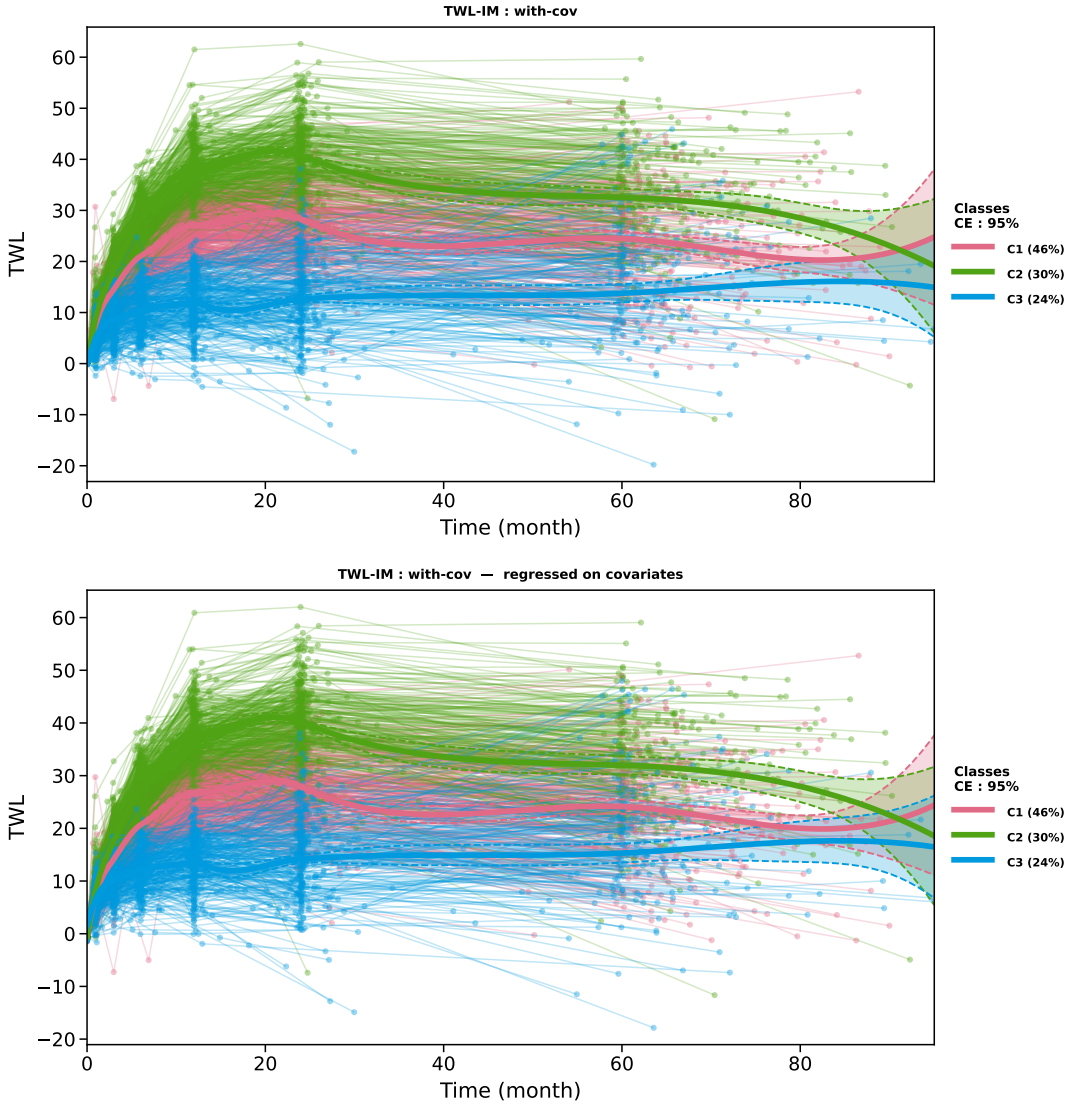


Figure 13 – Analyse « TWL-IM : with-cov » (InfoMergeCluster, $K = 3$ imposé), ajustée sur l'âge à l'intervention, la technique chirurgicale, le statut tabagique et le statut diabétique : données brutes (en haut) et données régressées sur ces quatre covariables (en bas). La légende indique la proportion de chaque classe et le niveau de l'enveloppe de confiance (CE : 95 %).

La partition est identique ; seules les ordonnées changent. Pour la classe k, l'écart brut–régressé vaut $(\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \hat{\boldsymbol{\gamma}}_k$: l'effet sur la TWL de la composition de la classe (âge, technique chirurgicale, statut tabagique, statut diabétique) par rapport à l'échantillon.

Les données régressées comparent les classes « à profil égal » ; les données brutes décrivent ce que les patients ont vécu. Dans les deux cas, les $\hat{\boldsymbol{\gamma}}_k$, estimés à partition fixée, ne sont pas des effets causaux.

8.3 Comparer plusieurs analyses

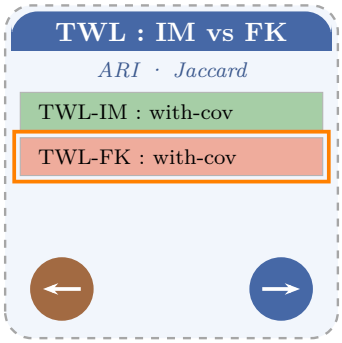
Deux façons de comparer des analyses d'un même projet :

— **Visuelle** : afficher les analyses ensemble, avec les mêmes bornes d'axes (**Zoom axes** sans sélection).

— **Quantitative** : concordance patient par patient (ARI et indice de Jaccard), dans des *boîtes de comparaison des modèles*.

Boîtes de comparaison

Dès qu'une boîte de comparaison existe (*Nouvelle comparaison* , barre droite), le panneau se partage : boîtes d'analyse à gauche (55 %), boîtes de comparaison à droite (45 %, titre **Comparisons**).



Nom de la comparaison (couleur facultative)
Indices choisis dans **Settings**

Une ligne par analyse : titre et couleur de sa boîte ;
cadre orange : ligne sélectionnée pour être retirée ;
cadre bleu : boîte d'analyse sélectionnée à gauche

Flèche gauche : retirer les analyses sélectionnées ;
flèche droite : ajouter les boîtes d'analyse sélectionnées

Figure 14 – Image d'une boîte de comparaison contenant deux analyses. Chaque flèche n'apparaît que lorsqu'elle peut servir.

1. **Créer la boîte** : *Nouvelle comparaison* , saisir un nom (par exemple « TWL : IM vs FK »), puis choisir une couleur ou conserver la couleur par défaut. Taille initiale 80 %, réglable par le curseur de la barre droite.

2. **Ajouter des analyses** : sélectionner une ou plusieurs boîtes d'analyse (Maj, Ctrl ou Cmd + clic pour en sélectionner plusieurs), puis cliquer sur la *flèche droite* de la boîte de comparaison. Pas de doublon ; une ligne par analyse, sur la couleur de sa boîte et portant son titre (nom de la boîte suivi de `no-cov` ou `with-cov`). La liste **Settings** de la comparaison rappelle en outre la méthode et la réponse de chaque analyse.

3. **Retirer des analyses** : cliquer sur une ou plusieurs lignes de la boîte de comparaison (cadre orange, autres lignes estompées), puis sur la *flèche gauche*. Une boîte d'analyse sélectionnée à gauche est encadrée de bleu dans toutes ses comparaisons et peut en être retirée de même.

4. **Choisir les indices** : *Configurer* ⚙ (barre droite) ou double-clic sur la boîte. Cases **ARI** (défaut) et **Jaccard**, côte à côte sous **Comparison index** ; couleur (**Choose…**, **Default**), puis **Save**.

5. **Lire les indices** : après **Run**, cocher **Comparisons** dans le panneau des résultats.

Suppression, renommage et restauration passent par la barre droite ; les comparaisons suivent les modifications des boîtes d'analyse. Tout s'annule par **Undo**.

Indices de concordance

Soient deux partitions $\mathcal{P}$ et $\mathcal{Q}$ des mêmes M patients, n_{uv} le nombre de patients affectés à la classe u de $\mathcal{P}$ et à la classe v de $\mathcal{Q}$, $a_u = \sum_v n_{uv}$ et $b_v = \sum_u n_{uv}$ les effectifs des classes. Les deux indices reposent sur le décompte des *paires* de patients :

$$S_{11} = \sum_{u,v} \binom{n_{uv}}{2}, \qquad S_a = \sum_u \binom{a_u}{2}, \qquad S_b = \sum_v \binom{b_v}{2}, \tag{11}$$

où S_{11} compte les paires regroupées dans les deux partitions, S_a et S_b les paires regroupées dans $\mathcal{P}$ et dans $\mathcal{Q}$ respectivement. L'indice de Rand ajusté (Hubert et Arabie, 1985) et l'indice de Jaccard (Jaccard, 1912) s'écrivent :

$$\mathrm{ARI} = \frac{S_{11} - S_a S_b / \binom{M}{2}}{\frac{1}{2}(S_a + S_b) - S_a S_b / \binom{M}{2}}, \qquad J = \frac{S_{11}}{S_a + S_b - S_{11}}. \tag{12}$$

Indice	Valeurs	Interprétation
ARI	≤ 1 ; espérance nulle sous indépendance	Concordance corrigée du hasard : 1 pour des partitions identiques, voisin de 0 pour un accord attendu au hasard compte tenu des effectifs des classes, négatif pour un accord inférieur au hasard
Jaccard	$[0, 1]$	Part des paires regroupées par les deux partitions parmi les paires regroupées par au moins l'une ; non corrigé du hasard, il augmente mécaniquement lorsque les classes sont peu nombreuses et de grande taille

Les indices ignorent les étiquettes (C1 ici peut être C2 là). Ils sont calculés par paire d'analyses exécutées, sur les M patients classés par les deux. Ici, les lignes au statut tabagique manquant étant supprimées en amont (annexe, section A.2), $M = 1\,438$ pour chaque paire. Sans ce nettoyage, une analyse avec covariables écarte les patients incomplets et M se réduit aux patients communs.

Afficher et exporter les indices

Comparisons ouvre une boîte déplaçable *Comparison results* : une section par comparaison, une ligne par paire : **Model 1**, **Model 2** (méthode, réponse et nombre de classes retenu ; nom de la boîte entre parenthèses lorsque deux analyses ont la même méthode et la même réponse), **N** (nombre de patients M), **ARI** et **Jaccard**. Indices arrondis à trois décimales ; indice non choisi : « — ». Un message signale les comparaisons incomplètes. **Export CSV** enregistre les indices en pleine précision, les analyses y étant désignées par le nom de leur boîte ; **Close** ferme.

Exemple : trois analyses du Poids

Cet exemple applique les étapes précédentes à trois analyses du Poids exécutées avec $K = 3$ (figure 15 ; sections 5.10 et 6.4) : InfoMergeCluster sans covariable (« Poids-IM »), InfoMergeCluster avec les quatre covariables (« Poids-IM2 ») et FKMS sans covariable (« Poids-FK »). Deux boîtes ne peuvent porter le même nom, d'où « Poids-IM2 ». Chaque boîte a sa couleur, reprise dans les boîtes de comparaison ; le contour bleu indique la sélection.

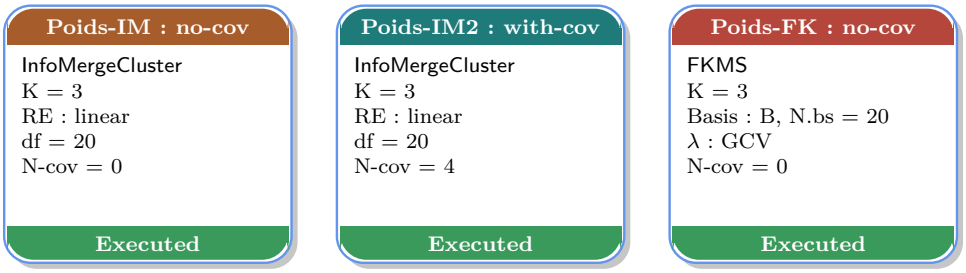


Figure 15 – Trois boîtes d'analyse exécutées, sélectionnées (contour bleu) pour être placées dans une même boîte de comparaison.

La paire « Poids-IM » / « Poids-FK » mesure l'effet de la méthode, à réponse et covariables égales ; la paire « Poids-IM » / « Poids-IM2 » mesure l'effet de l'ajustement sur les covariables, à méthode égale.

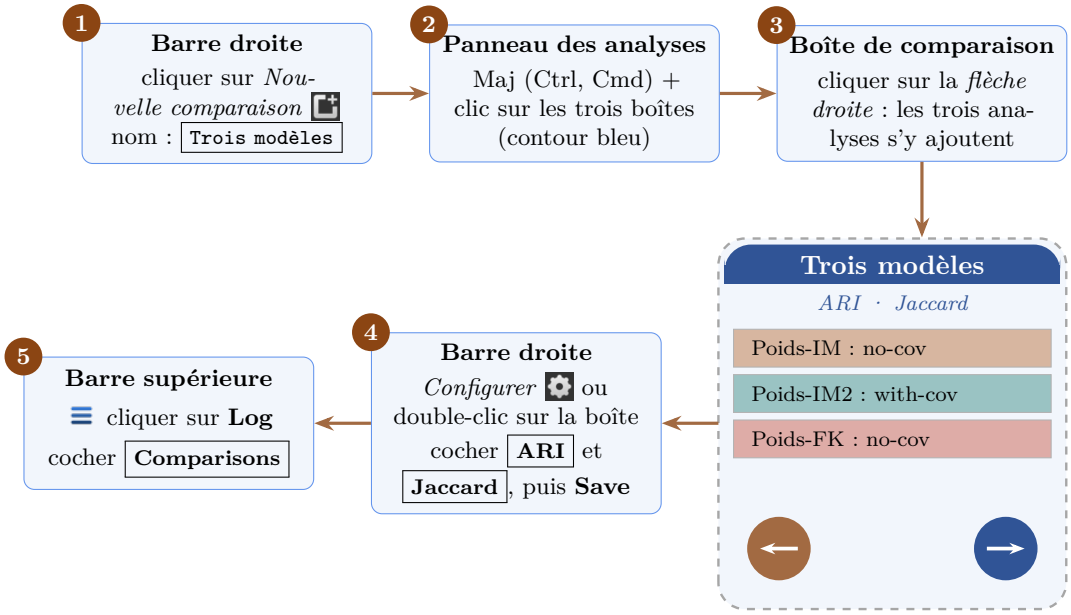


Figure 16 – Étapes de la comparaison des trois analyses (mêmes étapes que la liste ci-dessus). À l'étape 3, la boîte de comparaison reçoit une ligne par analyse, sur la couleur de sa boîte et désignée par le titre de cette boîte (nom suivi de `no-cov` ou `with-cov`).

Les indices se calculent sur les partitions enregistrées, sans relancer **Run** ; toute analyse non Executed doit être exécutée avant l'étape 5. Trois analyses donnent trois paires, toutes sur $M = 1\,438$ patients (tableau 10).

Model 1	Model 2	N	ARI	Jaccard
InfoMergeCluster : Poids (Poids-IM)	InfoMergeCluster : Poids (Poids-IM2)	1 438	0.942	0.937
InfoMergeCluster : Poids (Poids-IM)	FKMS : Poids	1 438	0.063	0.299
InfoMergeCluster : Poids (Poids-IM2)	FKMS : Poids	1 438	0.060	0.299

Tableau 10 – Boîte *Comparison results* pour la comparaison « Trois modèles » ($K = 3$ pour les trois analyses) : une ligne par paire d'analyses, sur les 1 438 patients classés par les deux analyses. Indices arrondis à trois décimales.

Lecture. Les indices se lisent comme indiqué plus haut (indices de concordance). L'ajustement sur les covariables modifie peu la partition du Poids par InfoMergeCluster : ARI de 0.94 et Jaccard de 0.94 entre « Poids-IM » et « Poids-IM2 ». À l'inverse, les partitions de InfoMergeCluster et de FKMS sont presque sans rapport : ARI voisin de 0.06, à peine au-dessus d'un accord dû au hasard. Le Jaccard d'environ 0.30 n'en est pas une contradiction : non corrigé du hasard, il reste élevé dès que les classes sont grandes. Ce désaccord est celui décrit en section 6.4 : FKMS regroupe les patients selon le niveau de poids initial, InfoMergeCluster selon la forme de la trajectoire (section 7).

Usages de la comparaison

- **Méthodes** : même réponse, deux méthodes (« Poids-IM » contre « Poids-FK », ARI 0.06 dans l'exemple). Un ARI faible malgré des proportions voisines signale des classes de mêmes tailles mais composées de patients différents.
- **Ajustement** : même analyse sans puis avec covariables (« Poids-IM » contre « Poids-IM2 », ARI 0.94).
- **Réponses** : Poids contre TWL, niveau pondéral contre perte relative.
- **Stabilité** : même configuration, deux graines ; à rapporter avec les résultats.

8.4 Exporter

- **Export des analyses** : un fichier CSV décrit chaque analyse (méthode, état, réponse, covariables, paramètres principaux, K retenu, proportions, BIC, ICL et log-vraisemblance pour InfoMergeCluster, MSE et λ par classe pour FKMS, nombres de patients et de mesures). `<nom>_clusters.csv` donne la classe de chaque patient par analyse, base des analyses a posteriori.
- **Export CSV des comparaisons** (boîte *Comparison results*) : une ligne par paire d'analyses comparées, avec la comparaison, les deux analyses (désignées par le nom de leur boîte), le nombre de patients, l'ARI et l'indice de Jaccard en pleine précision.
- **Save plot** : graphiques en PNG, PDF, SVG, JPEG ou TIFF à la résolution choisie, ou regroupés dans un document Word ; le titre de chaque graphique est le nom de sa boîte d'analyse.
- **Capture** : image de la fenêtre.
- **Save** : données, paramètres et résultats, pour reproduire l'étude.

A. Description des données de la cohorte ABOS

Les trois réponses longitudinales (Poids, BMI, TWL) dérivent toutes du poids corporel.

A.1 Données et schéma d'observation

L'échantillon source comprend $N = 1\,443$ patients de la cohorte ABOS, pour un total de $n = \sum_{i=1}^{N} n_i = 8\,734$ observations, sans couple (patient, instant) dupliqué. Le nombre d'observations par patient n_i varie de 2 à 7 (moyenne 6.05 ; écart-type 1.07 ; médiane 6), et les instants de mesure t_{ij} s'étendent de 0 à 95 mois après l'intervention. Seul le statut tabagique a des valeurs manquantes (section A.2).

Les données sont issues de la cohorte ABOS (*A Biological Atlas of Severe Obesity*, NCT01129297), cohorte prospective monocentrique de patients atteints d'obésité sévère ou massive opérés d'une chirurgie bariatrique au CHU de Lille, avec inclusions depuis 2006. Les fichiers sources comportent 16 variables (voir tableau 11), réparties en quatre catégories :

— **Identification et schéma d'observation** : `Patient`, `Time`, `n_obs`, `Dataset`.

— **Mesures anthropométriques répétées** : `Poids`, `BMI`, `TWL`.

— **Valeurs de base (à l'intervention, $t = 0$)** : `M000..Clini_Poids`, `M000..Clini_BMI`.

— **Covariables de base, invariantes dans le temps** : `IEX_PATIENT..ABOS_taillecm`, `AgeJourIntervention__lcn`, `ABOS_Intervention`, `M000..TabacFumeur`, `M000..ABOS_Diabete_Oui__lc`, `M000_AnneeAvecDiab`, `TWL_pre_surg`.

Tableau 11 – Dictionnaire des variables.

Variable	Description	Unité
`Patient`	Identifiant du sujet i, $i = 1, \ldots, N$; unité statistique	–
`Time`	Délai post-opératoire t_{ij}	mois
`TWL`	Pourcentage de perte de poids totale (*Total Weight Loss*) TWL_{ij} du sujet i à l'instant t_{ij}	%
`Poids`	Poids corporel P_{ij} du sujet i à l'instant t_{ij}	kg
`BMI`	Indice de masse corporelle (*Body Mass Index*) BMI_{ij} du sujet i à l'instant t_{ij}	kg/m^2
`IEX_PATIENT..ABOS_taillecm`	Taille h_i du sujet i	cm
`ABOS_Intervention`	Technique chirurgicale (bypass gastrique, *sleeve* gastrectomie, anneau gastrique)	–
`M000..Clini_Poids`	Poids de base P_{i0}, mesuré le jour de l'intervention	kg
`M000..Clini_BMI`	BMI de base BMI_{i0}, mesuré le jour de l'intervention	kg/m^2
`AgeJourIntervention__lcn`	Âge a_i à l'intervention, invariant dans le temps	années
`M000..TabacFumeur`	Statut tabagique (fumeur, non-fumeur ; non renseigné pour 5 sujets)	–
`TWL_pre_surg`	Perte de poids pré-opératoire	%
`M000..ABOS_Diabete_Oui__lc`	Statut diabétique (0 = non, 1 = DT1, 2 = DT2)	–
`Dataset`	Origine des données	–
`M000_AnneeAvecDiab`	Ancienneté du diabète	années
`n_obs`	Nombre n_i d'observations du sujet i	–

Variables listées dans l'ordre des fichiers sources (14 833 lignes, toutes cohortes confondues). Le préfixe M000 désigne une mesure recueillie à la visite d'inclusion (mois 0, jour de l'intervention). La plupart des variables sont stockées au format caractère dans les fichiers sources et converties au format numérique lors du prétraitement. DT1 et DT2 désignent respectivement les diabètes de type 1 et de type 2.

Source de la cohorte : *A Biological Atlas of Severe Obesity (Biological Tissue Collection)*, NCT01129297, ClinicalTrials.gov, `https://clinicaltrials.gov/study/NCT01129297`.

A.2 Valeurs manquantes

Valeurs manquantes avant exclusion, par délai post-opératoire (tableau 12).

Tableau 12 – Valeurs manquantes par variable et par délai post-opératoire, avant exclusion (échantillon source).

	Délai post-opératoire (mois)								
Variable	≤ 0	$]0\,;6]$	$]6\,;12]$	$]12\,;24]$	$]24\,;36]$	$]36\,;60]$	> 60	Total	Patients
`M000..TabacFumeur`	5 (0.3)	11 (0.3)	5 (0.4)	2 (0.2)	2 (0.3)	1 (0.7)	–	26 (0.3)	5
Nombre de mesures	1 443	3 362	1 281	1 255	688	141	564	8 734	1 443

Effectif des mesures dont la valeur de la variable est manquante ; entre parenthèses, pourcentage des mesures manquantes réalisées dans l'intervalle de délai considéré (colonne Total : pourcentage de l'ensemble des mesures manquantes pour la variable). Patients : nombre de patients ayant au moins une valeur manquante pour la variable. Les variables non listées (identifiant, délai, Poids, BMI, TWL, âge, statut diabétique, technique chirurgicale) ne comportent aucune valeur manquante. Codes traités comme manquants : chaîne vide, `NA`, `N/A`, `NaN`, `NULL`, `..`

— **Mécanisme.** Le statut tabagique est une covariable de base, recueillie à l'inclusion et constante pour un patient. Sa valeur manque pour 5 patients (0.3 % des patients), et donc

pour la totalité de leurs 26 mesures. Leur répartition dans le temps suit le calendrier de ces cinq patients : la donnée manque au niveau du patient, pas de la visite.

— **Traitement.** Suppression des lignes concernées : $N = 1\,438$ patients et $n = 8\,708$ observations (médiane 6 par patient), pour toutes les analyses. L'exclusion (0.3 % des patients) pèse peu sur les partitions.

A.3 Relations déterministes entre les variables réponses

Soit h_i la taille du sujet i (variable `IEX_PATIENT..ABOS_taillecm`, convertie en mètres). Les relations suivantes sont vérifiées :

$$\mathrm{BMI}_{ij} = \frac{P_{ij}}{h_i^2}, \qquad \mathrm{BMI}_{i0} = \frac{P_{i0}}{h_i^2}, \tag{13}$$

$$\mathrm{TWL}_{ij} = 100\,\frac{P_{i0} - P_{ij}}{P_{i0}} = 100\left(1 - \frac{\mathrm{BMI}_{ij}}{\mathrm{BMI}_{i0}}\right). \tag{14}$$

Il en découle les propriétés suivantes, utiles pour le clustering.

— **BMI et Poids.** Le BMI d'un patient est son Poids multiplié par $1/h_i^2$: profils proportionnels, facteur d'échelle propre au patient. Cette normalisation retire l'effet de la taille, pas celui de la corpulence initiale.

— **TWL et Poids.** La TWL, critère recommandé pour exprimer la perte de poids après chirurgie bariatrique (Corcelles et al., 2016), est une transformation affine du poids, de coefficients propres au patient. Nulle à $t = 0$, positive en cas de perte, négative au-dessus du poids de base, elle élimine le niveau initial et mesure la variation relative du poids.

— **Dépendance des trois analyses.** Les trois analyses portent sur un même signal et ne sont pas indépendantes. Pour le Poids et le BMI, la variance entre patients tient surtout au niveau initial ; pour la TWL, à la dynamique de perte.

Moyenne et écart-type des trois réponses : tableau 13.

Tableau 13 – Statistiques descriptives marginales des trois variables réponses (échantillon source, avant exclusion).

Variable réponse	Unité	Moyenne (écart-type), $n = 8\,734$
Poids	kg	109.8 (26.9)
BMI	kg/m^2	38.9 (8.5)
TWL	%	16.4 (12.9)

Sur les 8 734 observations, tous instants confondus : ordre de grandeur, pas évolution.

Références

D. Arthur et S. Vassilvitskii. k-means++ : the advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035. SIAM, Philadelphie, 2007.

C. Biernacki, G. Celeux et G. Govaert. Assessing a mixture model for clustering with the integrated completed likelihood. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(7) :719–725, 2000.

R. Corcelles, C. R. Boules, D. Froylich, A. Hag, E. Z. Daigle, S. A. Brethauer, P. R. Schauer et M. Kroh. Total weight loss as the outcome measure of choice after Roux-en-Y gastric bypass. *Obesity Surgery*, 26(8) :1794–1798, 2016.

P. Craven et G. Wahba. Smoothing noisy data with spline functions. *Numerische Mathematik*, 31(4) :377–403, 1979.

C. de Boor. *A Practical Guide to Splines*, édition révisée. Applied Mathematical Sciences 27. Springer, New York, 2001.

A. P. Dempster, N. M. Laird et D. B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society, Series B*, 39(1) :1–38, 1977.

P. J. Diggle. An approach to the analysis of repeated measurements. *Biometrics*, 44(4) :959–971, 1988.

L. Hubert et P. Arabie. Comparing partitions. *Journal of Classification*, 2(1) :193–218, 1985.

P. Jaccard. The distribution of the flora in the alpine zone. *New Phytologist*, 11(2) :37–50, 1912.

N. M. Laird et J. H. Ware. Random-effects models for longitudinal data. *Biometrics*, 38(4) :963–974, 1982.

K.-Y. Liang et S. L. Zeger. Longitudinal data analysis using generalized linear models. *Biometrika*, 73(1) :13–22, 1986.

S. P. Lloyd. Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2) :129–137, 1982.

G. J. McLachlan et D. Peel. *Finite Mixture Models*. Wiley, New York, 2000.

F. O'Sullivan. A statistical perspective on ill-posed inverse problems. *Statistical Science*, 1(4) :502–518, 1986.

D. Ruppert, M. P. Wand et R. J. Carroll. *Semiparametric Regression*. Cambridge University Press, Cambridge, 2003.

G. Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2) :461–464, 1978.

S. N. Wood et M. Fasiolo. A generalized Fellner–Schall method for smoothing parameter optimization with application to Tweedie location, scale and shape models. *Biometrics*, 73(4) :1071–1081, 2017.